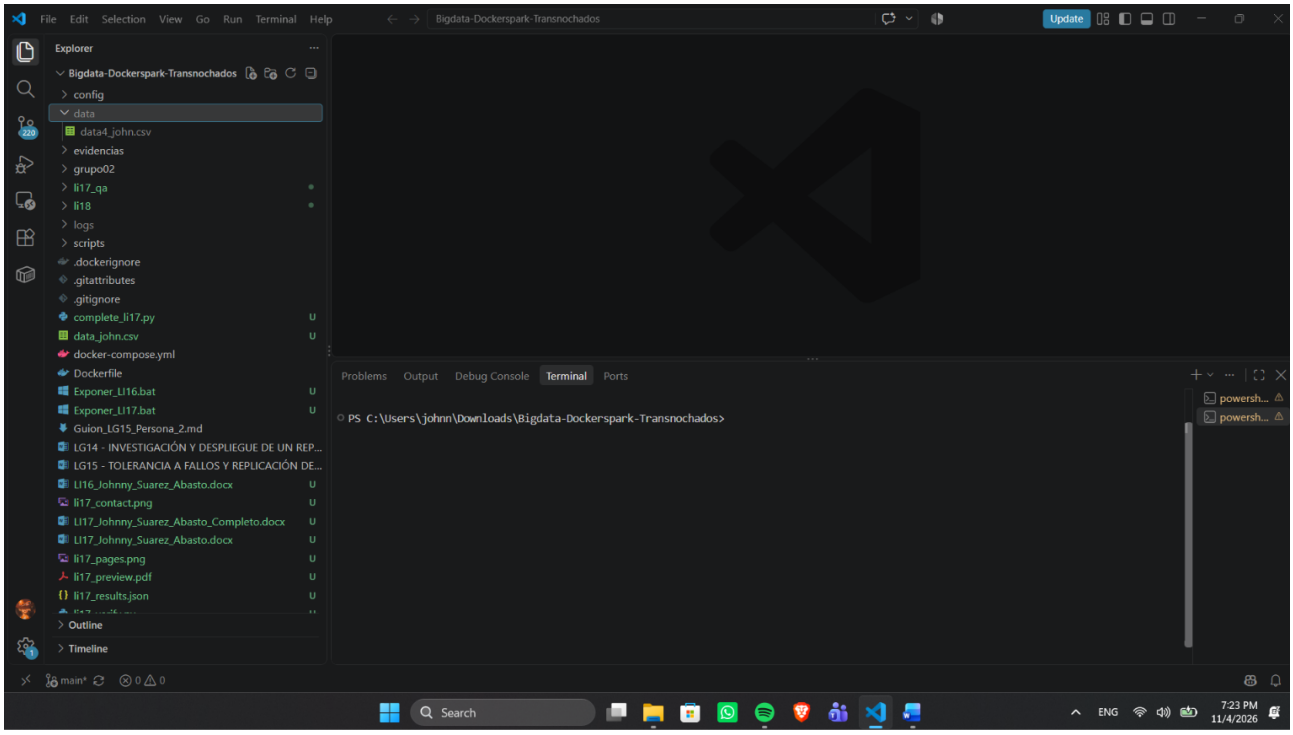
UNIVERSIDAD DEL VALLE

LI19 - Practica con Apache Hive (4)

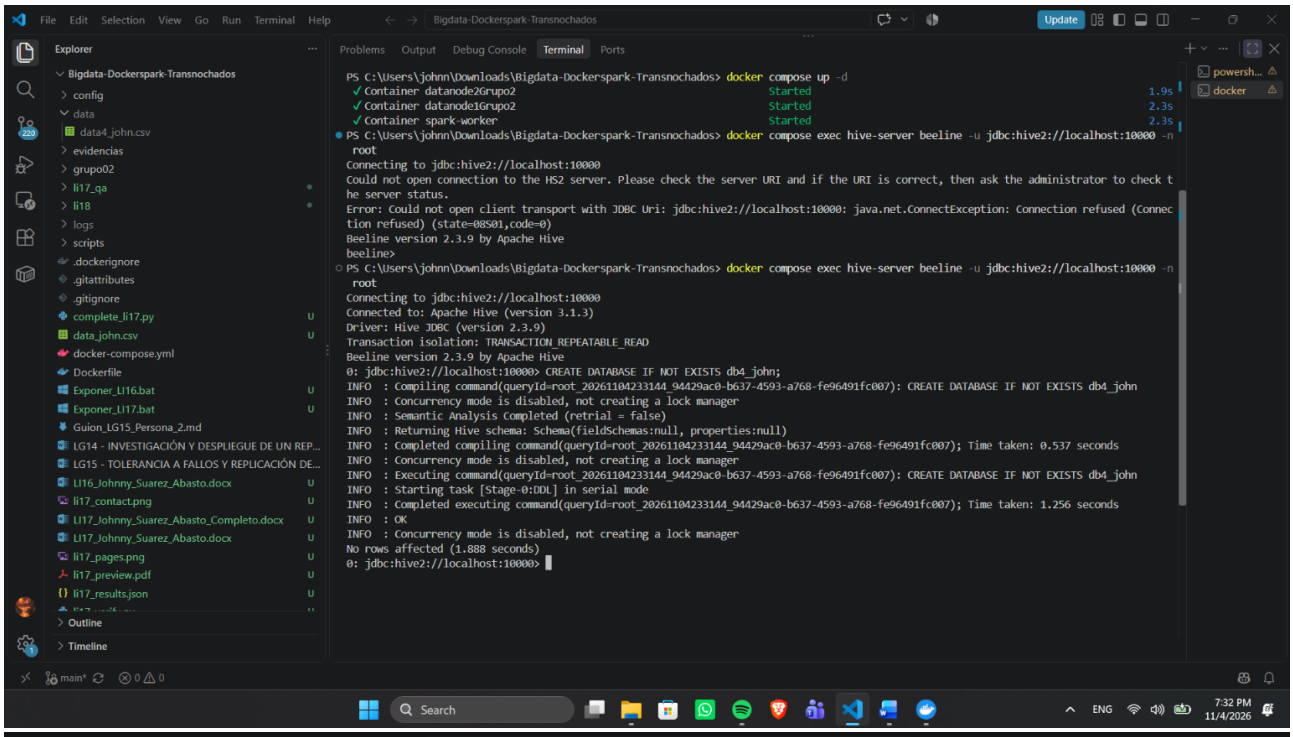
Nombre: Johnny Suarez Abasto
Docente: Ing. Efrain Luna Mamani
Para este laboratorio, se asume que ya tiene Apache Hive corriendo:

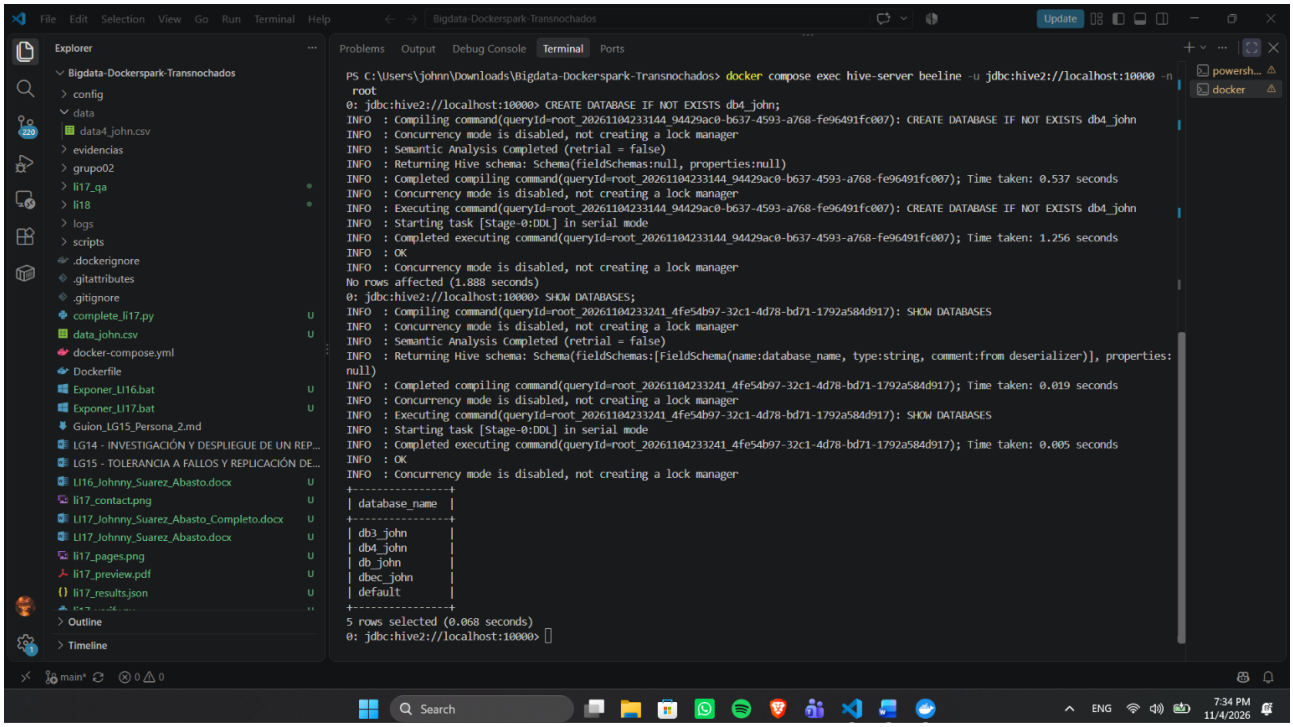
1. Descargue el siguiente dataset:
   https://www.kaggle.com/datasets/Microsoft/microsoft-security-incident-prediction

2. La descarga anterior le presentará dos archivos; usaremos el denominado “GUIDE_Test.csv”, el cual deberá renombrar a **data4_tunombre.csv**

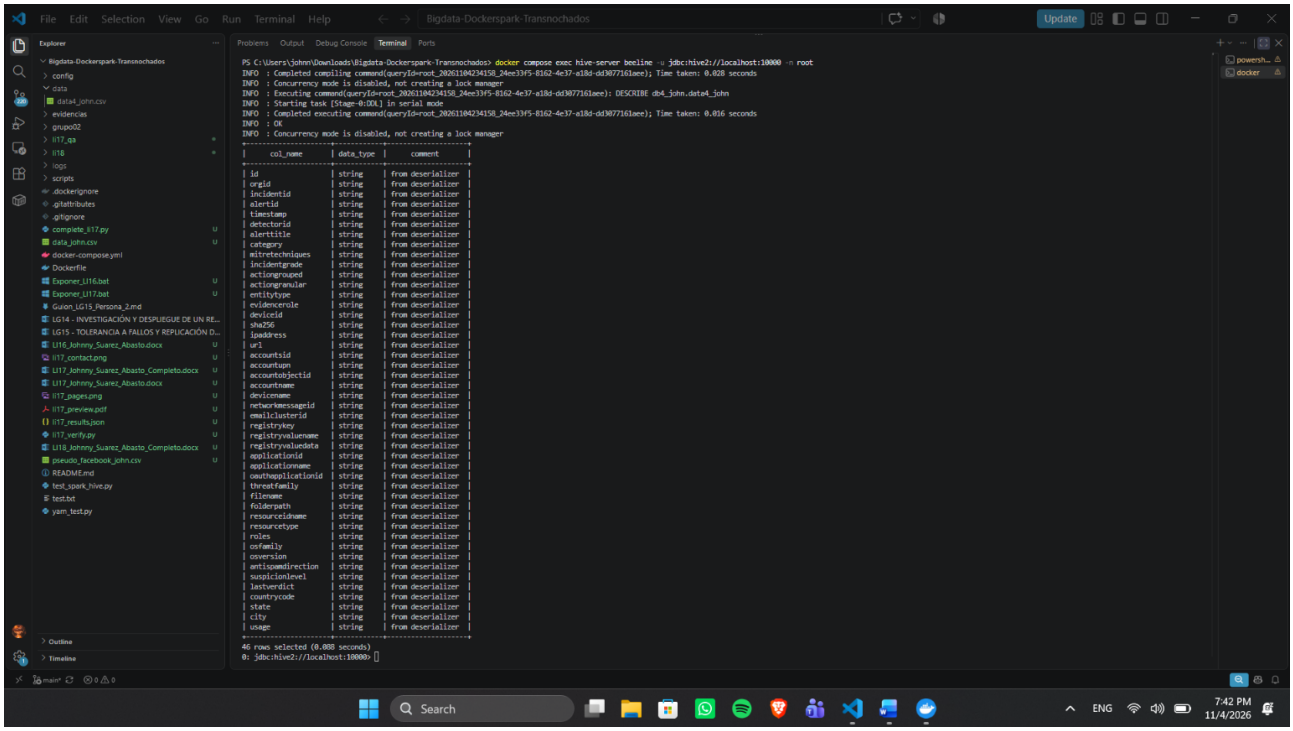


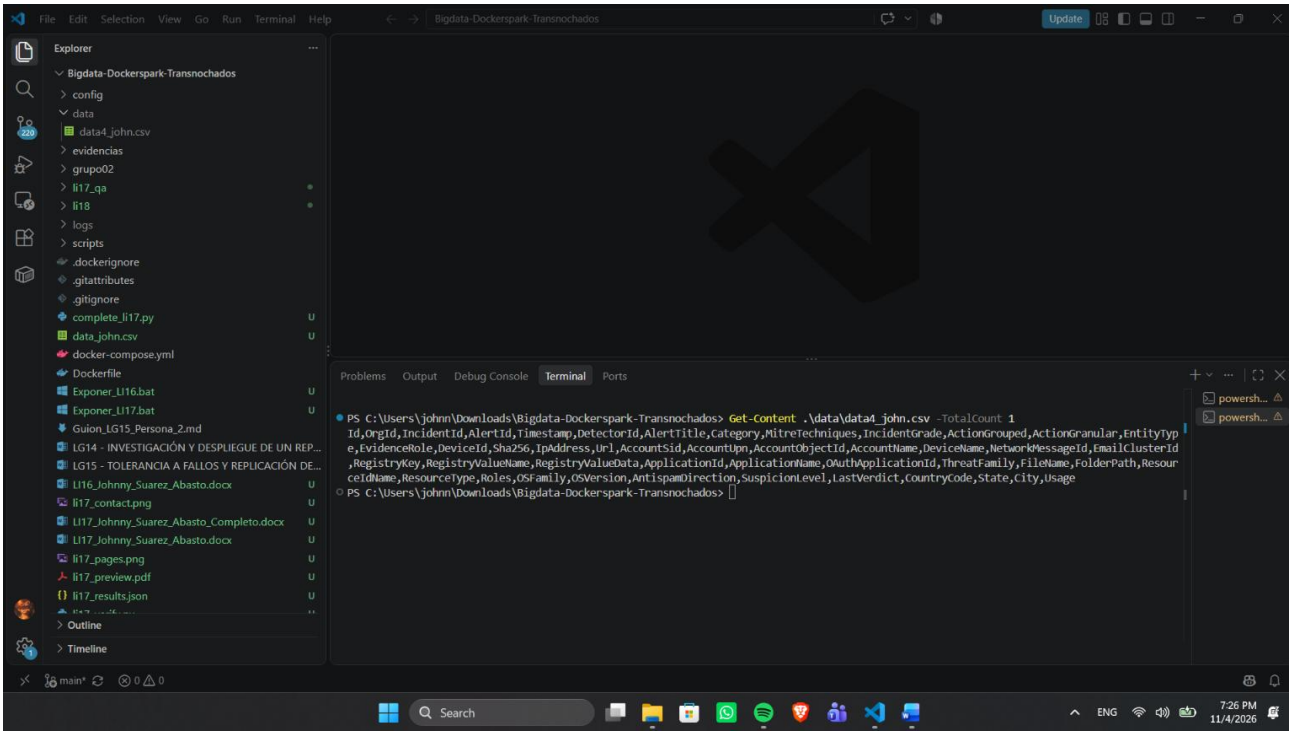
3. Acceder a Hive desde el contenedor **docker-hive_hive-server_1** con el comando: hive
   a. Crear una base de datos denominada **db4_tunombre** con el comando:
      create database **db4_tunombre;**


File Edit Selection View Go Run Terminal Help
Bigdata-Dockerspark-Transnochados
Update
Explorer
Problems Output Debug Console Terminal Ports
Bigdata-Dockerspark-Transnochados
config
data
data4_john.csv
evidencias
grupo02
li17_qa
li18
logs
scripts
.dockerignore
.gitattributes
.gitignore
complete_li17.py
data_john.csv
docker-compose.yml
Dockerfile
Exponer_LI16.bat
Exponer_LI17.bat
Guion_LG15_Persona_2.md
LG14 - INVESTIGACIÓN Y DESPLIEGUE DE UN REP...
LG15 - TOLERANCIA A FALLOS Y REPLICACIÓN DE...
LI16_Johnny_Suarez_Abasto.docx
li17_contact.png
LI17_Johnny_Suarez_Abasto_Completo.docx
LI17_Johnny_Suarez_Abasto.docx
li17_pages.png
li17_preview.pdf
li17_results.json
Outline
Timeline
PS C:\Users\johnn\Downloads\Bigdata-Dockerspark-Transnochados> docker compose up -d
Container datanode2Grupo2 Started 1.9s
Container datanode1Grupo2 Started 2.3s
Container spark-worker Started 2.3s
PS C:\Users\johnn\Downloads\Bigdata-Dockerspark-Transnochados> docker compose exec hive-server beeline -u jdbc:hive2://localhost:10000 -n root
Connecting to jdbc:hive2://localhost:10000
Could not open connection to the HS2 server. Please check the server URI and if the URI is correct, then ask the administrator to check the server status.
Error: Could not open client transport with JDBC Uri: jdbc:hive2://localhost:10000: java.net.ConnectException: Connection refused (Connection refused) (state=08S01,code=0)
Beeline version 2.3.9 by Apache Hive
beeline>
PS C:\Users\johnn\Downloads\Bigdata-Dockerspark-Transnochados> docker compose exec hive-server beeline -u jdbc:hive2://localhost:10000 -n root
Connecting to jdbc:hive2://localhost:10000
Connected to: Apache Hive (version 3.1.3)
Driver: Hive JDBC (version 2.3.9)
Transaction isolation: TRANSACTION_REPEATABLE_READ
Beeline version 2.3.9 by Apache Hive
0: jdbc:hive2://localhost:10000> CREATE DATABASE IF NOT EXISTS db4_john;
INFO : Compiling command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007): CREATE DATABASE IF NOT EXISTS db4_john
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007); Time taken: 0.537 seconds
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Executing command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007): CREATE DATABASE IF NOT EXISTS db4_john
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007); Time taken: 1.256 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
No rows affected (1.888 seconds)
0: jdbc:hive2://localhost:10000>
powersh...
docker
main*
Search
ENG
7:32 PM
11/4/2026


File Edit Selection View Go Run Terminal Help
Bigdata-Dockerspark-Transnochados
Update
Explorer
Problems Output Debug Console Terminal Ports
Bigdata-Dockerspark-Transnochados
config
data
data4_john.csv
evidencias
grupo02
li17_qa
li18
logs
scripts
.dockerignore
.gitattributes
.gitignore
complete_li17.py
data_john.csv
docker-compose.yml
Dockerfile
Exponer_LI16.bat
Exponer_LI17.bat
Guion_LG15_Persona_2.md
LG14 - INVESTIGACIÓN Y DESPLIEGUE DE UN REP...
LG15 - TOLERANCIA A FALLOS Y REPLICACIÓN DE...
LI16_Johnny_Suarez_Abasto.docx
li17_contact.png
LI17_Johnny_Suarez_Abasto_Completo.docx
LI17_Johnny_Suarez_Abasto.docx
li17_pages.png
li17_preview.pdf
li17_results.json
Outline
Timeline
PS C:\Users\johnn\Downloads\Bigdata-Dockerspark-Transnochados> docker compose exec hive-server beeline -u jdbc:hive2://localhost:10000 -n root
0: jdbc:hive2://localhost:10000> CREATE DATABASE IF NOT EXISTS db4_john;
INFO : Compiling command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007): CREATE DATABASE IF NOT EXISTS db4_john
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:null, properties:null)
INFO : Completed compiling command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007); Time taken: 0.537 seconds
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Executing command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007): CREATE DATABASE IF NOT EXISTS db4_john
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=root_20261104233144_94429ac0-b637-4593-a768-fe96491fc007); Time taken: 1.256 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
No rows affected (1.888 seconds)
0: jdbc:hive2://localhost:10000> SHOW DATABASES;
INFO : Compiling command(queryId=root_20261104233241_4fe54b97-32c1-4d78-bd71-1792a584d917): SHOW DATABASES
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Semantic Analysis Completed (retrial = false)
INFO : Returning Hive schema: Schema(fieldSchemas:[FieldSchema(name:database_name, type:string, comment:from deserializer)], properties:null)
INFO : Completed compiling command(queryId=root_20261104233241_4fe54b97-32c1-4d78-bd71-1792a584d917); Time taken: 0.019 seconds
INFO : Concurrency mode is disabled, not creating a lock manager
INFO : Executing command(queryId=root_20261104233241_4fe54b97-32c1-4d78-bd71-1792a584d917): SHOW DATABASES
INFO : Starting task [Stage-0:DDL] in serial mode
INFO : Completed executing command(queryId=root_20261104233241_4fe54b97-32c1-4d78-bd71-1792a584d917); Time taken: 0.005 seconds
INFO : OK
INFO : Concurrency mode is disabled, not creating a lock manager
+----------------+
| database_name |
+----------------+
| db3_john |
| db4_john |
| db_john |
| dbec_john |
| default |
+----------------+
5 rows selected (0.068 seconds)
0: jdbc:hive2://localhost:10000>
powersh...
docker
main*
Search
ENG
7:34 PM
11/4/2026

4. Identifique qué columnas tiene su archivo **data4_tunombre.csv** y determine los tipos de datos que le corresponden:





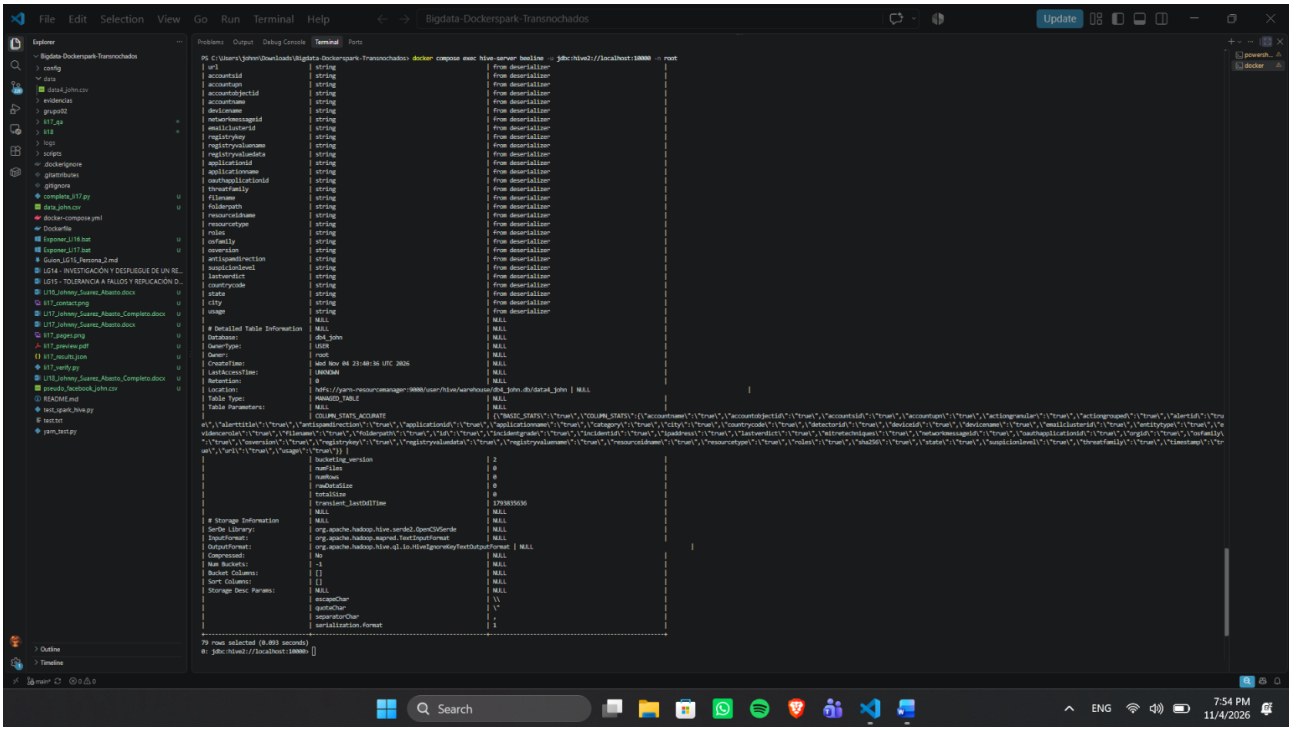
Columna	Tipo de dato	Comentario del analista	Comentario del profesor
Id	BIGINT		
OrgId	INT		
IncidentId	BIGINT		
AlertId	BIGINT		

Timestamp	STRING		Usted puede usar el tipo como string y posteriormente en el SQL convertirlo al tipo que requiera.
…			

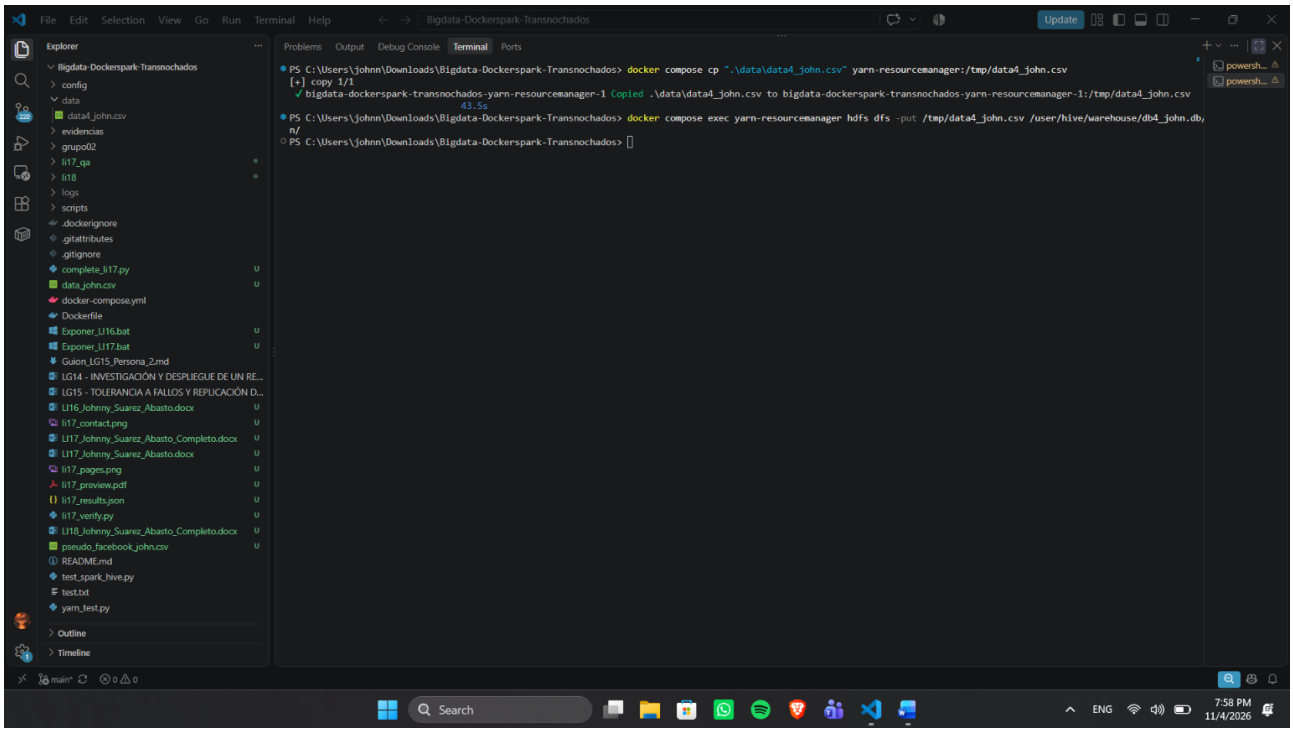
La tabla debe incluir el análisis por cada campo y declararlo en la tabla en las columnas: “columna”, “tipo de dato” y “comentario del analista” (este refiere a los campos que tengan particularidades que puedan complicar su tratamiento).

a. Crear una tabla denominada **data4_tunombre** tomando en cuenta los tipos de datos definidos anteriormente (revisa tu anterior práctica para guiarte).

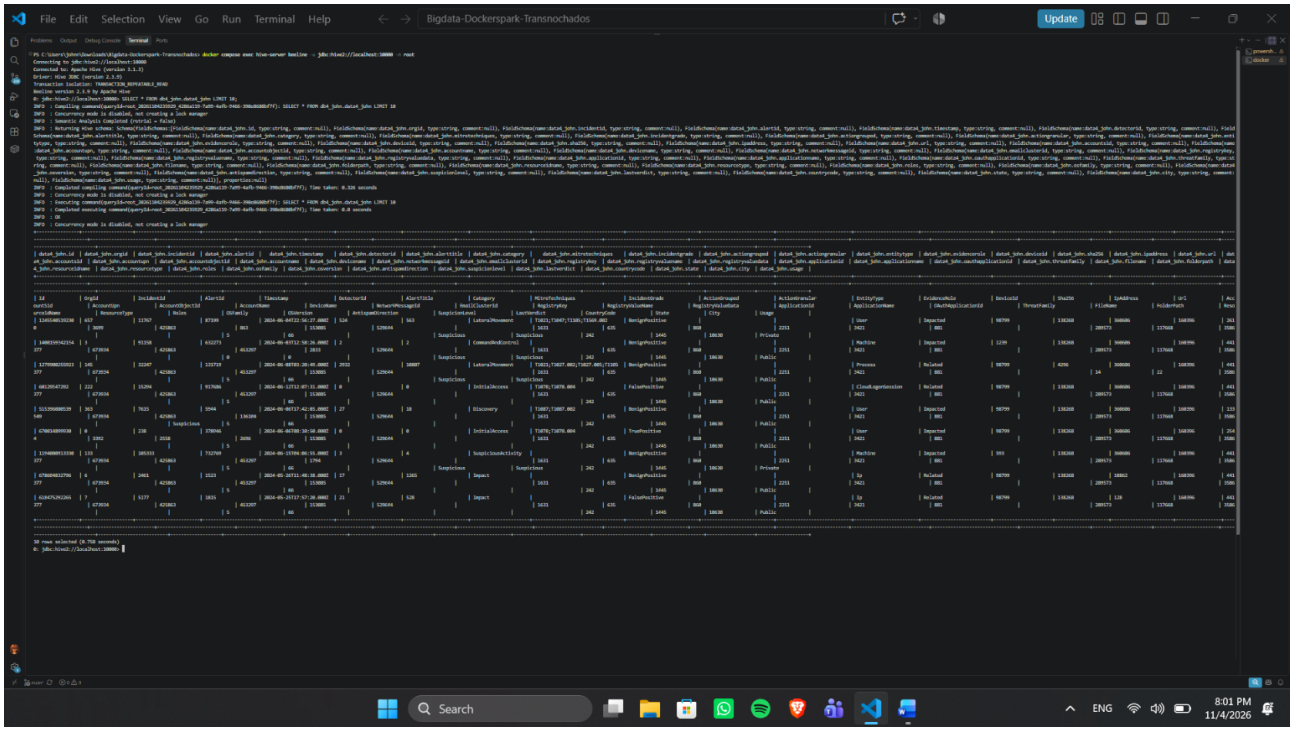
b. Revisa que el valor de location llegue hasta la tabla creada **data4_tunombre** con el comando: DESCRIBE FORMATTED **db4_tunombre**.**data4_tunombre**;



c. Cargar los datos del CSV a la tabla creada.



d. Mostrar los primeros 10 registros para validar que la carga se realizó correctamente.



5. Los siguientes son preguntas que ya vienen con su respuesta y una descripción del KPI que se está obteniendo; en este punto particular deberá:
    a. La tabla está completamente desordenada, es decir, se hizo un random de la columna pregunta, SQL solución y la descripción, no debe guiarse por el mismo más que solo como un punto de partida.
    b. Usted debe primero comprender la pregunta.
    c. Debe probar cada SQL sugerido y considerar a qué pregunta responde el mismo.
    d. Determinar qué descripción le corresponde.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
1	¿Qué tipos de entidades aparecen con mayor frecuencia en los eventos?	SELECT trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM siem_event_logs LATERAL VIEW explode(split(MitreTechniques, ';')) mitre_table AS tecnica WHERE Category = 'LateralMovement' AND MitreTechniques IS NOT NULL AND MitreTechniques <> '' AND trim(tecnica) <> '' GROUP BY trim(tecnica) ORDER BY total_eventos DESC;	Agrupa los eventos por fecha. Permite observar días con mayor actividad o picos anómalos de eventos.
2	¿Qué técnicas MITRE aparecen dentro de cada categoría de amenaza?	SELECT trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM (SELECT explode(split(MitreTechniques, ';')) AS tecnica FROM siem_event_logs WHERE MitreTechniques IS NOT NULL AND MitreTechniques <> '') t WHERE trim(tecnica) <> '' GROUP BY trim(tecnica) ORDER BY total_eventos DESC;	Agrupa los eventos según el nivel de sospecha. Ayuda a identificar cuántos eventos fueron clasificados como sospechosos, desconocidos o sin clasificación.
3	¿Qué técnica MITRE aparece más en eventos de movimiento lateral?	SELECT IpAddress, COUNT(*) AS total_eventos FROM siem_event_logs WHERE IpAddress IS NOT NULL AND IpAddress <> '' GROUP BY IpAddress ORDER BY total_eventos DESC LIMIT 20;	Calcula un puntaje simple de riesgo para priorizar eventos. No reemplaza un SIEM real, pero sirve para practicar reglas de clasificación y priorización SOC.
4	¿Qué incidentes concentran más alertas?	SELECT IncidentId, COUNT(DISTINCT AlertId) AS total_alertas, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY IncidentId ORDER BY total_alertas DESC LIMIT 20;	Identifica cuentas vinculadas directamente a evidencias impactadas. Es útil para priorizar usuarios posiblemente afectados o comprometidos.
5	¿Qué **horas** tienen mayor concentración de eventos sospechosos?	SELECT IncidentGrade, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY IncidentGrade ORDER BY total_eventos DESC;	Identifica las cuentas de usuario más asociadas a eventos de seguridad. Es útil para detectar cuentas comprometidas o usuarios con actividad sospechosa.
6	¿Qué eventos pueden considerarse de mayor riesgo usando una regla simple basada en categoría, sospecha y veredicto?	SELECT Id, IncidentId, AlertId, Category, IncidentGrade, SuspicionLevel, LastVerdict, EntityType, EvidenceRole, (CASE WHEN Category IN ('LateralMovement', 'CredentialAccess', 'Malware', 'Execution') THEN 40 ELSE 10 END + CASE WHEN SuspicionLevel = 'Suspicious' THEN 30 ELSE 0 END + CASE WHEN LastVerdict = 'Suspicious' THEN 20 ELSE 0 END + CASE WHEN EvidenceRole = 'Impacted' THEN 10 ELSE 0 END) AS score_riesgo FROM siem_event_logs ORDER BY score_riesgo DESC LIMIT 50;	Identifica las técnicas MITRE más frecuentes dentro de la categoría `LateralMovement`. Es útil para analizar tácticas relacionadas con desplazamiento lateral dentro de una red.
7	¿Qué dispositivos aparecen en incidentes con más de una alerta?	SELECT EvidenceRole, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY EvidenceRole ORDER BY total_eventos DESC;	Identifica los 10 detectores con mayor volumen de eventos. Permite reconocer reglas, sensores o mecanismos de detección que generan

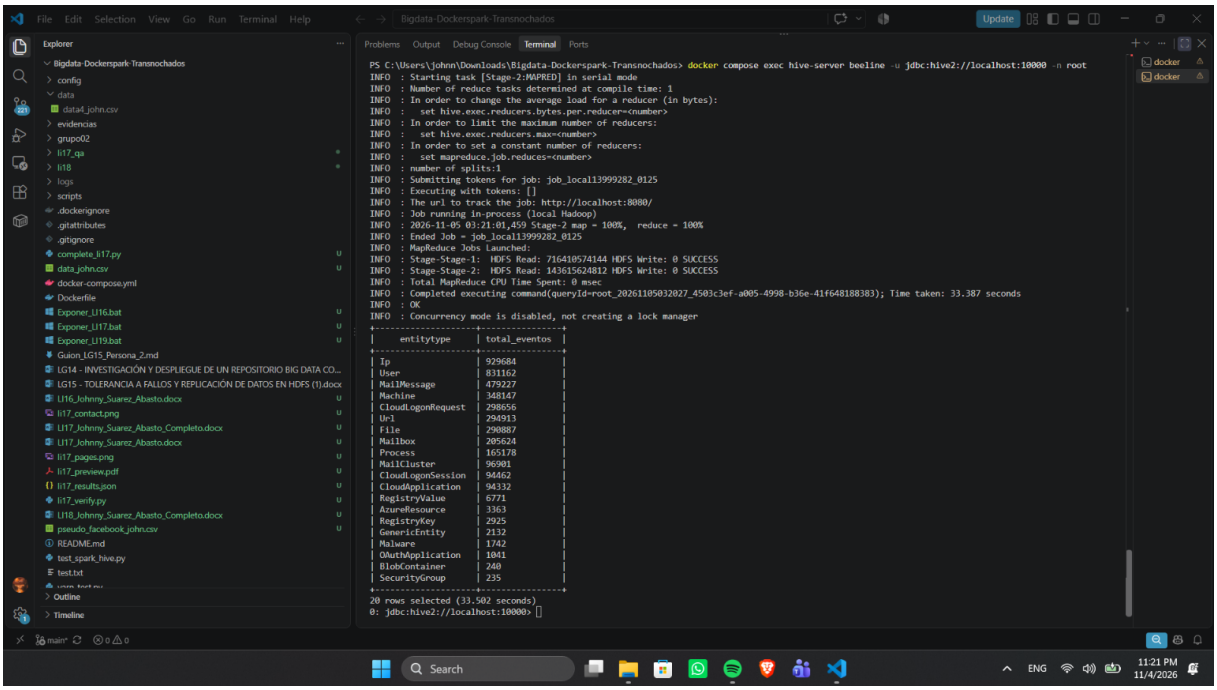
			más alertas.
8	¿Qué direcciones IP aparecen más veces en los eventos?	SELECT EntityType, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY EntityType ORDER BY total_eventos DESC;	Muestra cuántos eventos tienen veredicto final, por ejemplo sospechoso, benigno, malicioso o sin veredicto. Sirve para evaluar el resultado del análisis de seguridad.
9	¿Qué cuentas están asociadas a eventos con evidencia impactada?	SELECT DeviceId, DeviceName, IncidentId, COUNT(DISTINCT AlertId) AS total_alertas FROM siem_event_logs WHERE DeviceId IS NOT NULL GROUP BY DeviceId, DeviceName, IncidentId HAVING COUNT(DISTINCT AlertId) > 1 ORDER BY total_alertas DESC;	Muestra dispositivos asociados a incidentes que tienen más de una alerta. Puede ayudar a identificar equipos involucrados en incidentes más complejos o persistentes.
10	¿Qué cuentas de usuario aparecen con mayor frecuencia en los eventos?	SELECT DeviceId, DeviceName, COUNT(*) AS total_eventos FROM siem_event_logs WHERE DeviceId IS NOT NULL GROUP BY DeviceId, DeviceName ORDER BY total_eventos DESC LIMIT 20;	Muestra la cantidad de eventos por hora, de 0 a 23. Sirve para identificar las franjas horarias con mayor actividad de seguridad.
11	¿Qué categorías tienen más eventos según el grado del incidente?	SELECT DetectorId, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY DetectorId ORDER BY total_eventos DESC LIMIT 10;	Muestra la cantidad de eventos según el rol de la evidencia. Ayuda a diferenciar entidades directamente afectadas de entidades solo relacionadas con el incidente.
12	¿Qué categoría tiene mayor cantidad de eventos sospechosos?	SELECT COUNT(*) AS total_eventos FROM siem_event_logs;	Muestra las alertas que tienen mayor cantidad de evidencias registradas. Sirve para identificar alertas con múltiples entidades, archivos, usuarios o dispositivos involucrados.
13	¿Qué alertas tienen más evidencias asociadas?	SELECT Category, trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM siem_event_logs LATERAL VIEW explode(split(MitreTechniques, ';')) mitre_table AS tecnica WHERE MitreTechniques IS NOT NULL AND MitreTechniques <> '' AND trim(tecnica) <> '' GROUP BY Category, trim(tecnica) ORDER BY total_eventos DESC;	Muestra las direcciones IP con mayor cantidad de eventos. Permite identificar IP internas o externas que aparecen repetidamente en los registros.
14	¿En qué **horas** del día se generan más eventos SIEM?	SELECT Category, IncidentGrade, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY Category, IncidentGrade ORDER BY total_eventos DESC;	Muestra las horas del día con mayor cantidad de eventos sospechosos. Permite identificar franjas

			horarias críticas para monitoreo SOC.
15	¿Cuántos eventos SIEM existen en el dataset?	SELECT Category, COUNT(*) AS total_sospechosos FROM siem_event_logs WHERE SuspicionLevel = 'Suspicious' OR LastVerdict = 'Suspicious' GROUP BY Category ORDER BY total_sospechosos DESC;	Muestra los incidentes con mayor cantidad de alertas asociadas. Permite identificar incidentes complejos o con gran volumen de evidencias.
16	¿Cuántos eventos se registraron por **día**?	SELECT Category, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY Category ORDER BY total_eventos DESC;	Muestra los títulos de alerta más frecuentes. Ayuda a detectar alertas repetitivas o patrones que podrían requerir revisión o ajuste.
17	¿Cuántos eventos existen por cada tipo de `IncidentGrade`?	SELECT CASE WHEN SuspicionLevel IS NULL OR SuspicionLevel = '' THEN 'Sin nivel de sospecha' ELSE SuspicionLevel END AS nivel_sospecha, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY CASE WHEN SuspicionLevel IS NULL OR SuspicionLevel = '' THEN 'Sin nivel de sospecha' ELSE SuspicionLevel END ORDER BY total_eventos DESC;	Muestra qué categorías concentran más eventos sospechosos. Sirve para identificar los tipos de amenazas que requieren mayor atención del analista.
18	¿Cuántos eventos existen por cada nivel de sospecha?	SELECT CASE WHEN LastVerdict IS NULL OR LastVerdict = '' THEN 'Sin veredicto' ELSE LastVerdict END AS veredicto_final, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY CASE WHEN LastVerdict IS NULL OR LastVerdict = '' THEN 'Sin veredicto' ELSE LastVerdict END ORDER BY total_eventos DESC;	Muestra un ranking de categorías de eventos, por ejemplo `LateralMovement`, `Malware`, `CredentialAccess`, entre otras. Permite identificar los tipos de amenazas más frecuentes.
19	¿Cuántos eventos corresponden a evidencias impactadas y cuántos a evidencias relacionadas?	SELECT AlertTitle, COUNT(*) AS total_alertas FROM siem_event_logs GROUP BY AlertTitle ORDER BY total_alertas DESC LIMIT 10;	Obtiene un ranking de dispositivos con más eventos. Puede ayudar a detectar equipos comprometidos, expuestos o con actividad anómala.
20	¿Cuáles son los títulos de alerta más repetidos en el dataset?	SELECT AlertId, COUNT(*) AS total_evidencias FROM siem_event_logs GROUP BY AlertId ORDER BY total_evidencias DESC LIMIT 20;	Permite identificar qué entidades aparecen con más frecuencia: usuarios, dispositivos, archivos, direcciones IP, aplicaciones u otros activos.
21	¿Cuáles son los dispositivos con mayor cantidad de eventos?	SELECT AccountName, AccountUpn, COUNT(*) AS total_eventos_impactados FROM siem_event_logs WHERE EvidenceRole = 'Impacted' AND (AccountName IS NOT NULL OR AccountUpn IS NOT NULL) GROUP BY AccountName, AccountUpn ORDER BY total_eventos_impactados DESC LIMIT 20;	Relaciona cada categoría de amenaza con las técnicas MITRE detectadas. Sirve para analizar qué técnicas predominan en cada tipo de incidente.

22	¿Cuáles son los detectores que generan mayor cantidad de alertas?	SELECT AccountName, AccountUpn, COUNT(*) AS total_eventos FROM siem_event_logs WHERE (AccountName IS NOT NULL AND AccountName <> '') OR (AccountUpn IS NOT NULL AND AccountUpn <> '') GROUP BY AccountName, AccountUpn ORDER BY total_eventos DESC LIMIT 20;	Relaciona la categoría del evento con el grado del incidente. Permite saber qué categorías se asocian más con incidentes benignos, sospechosos o confirmados.
23	¿Cuáles son las técnicas MITRE ATT&CK más utilizadas o detectadas?	SELECT to_date(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS fecha_evento, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY to_date(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY fecha_evento;	Se obtiene la cantidad total de registros cargados en la tabla. Sirve para validar si el CSV fue cargado correctamente en Hive.
24	¿Cuáles son las categorías de eventos más frecuentes?	SELECT hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS hora_evento, COUNT(*) AS total_eventos_sospechosos FROM siem_event_logs WHERE SuspicionLevel = 'Suspicious' OR LastVerdict = 'Suspicious' GROUP BY hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY total_eventos_sospechosos DESC;	Se obtiene la distribución de eventos según su clasificación, por ejemplo benignos, sospechosos, positivos verdaderos o falsos positivos, dependiendo de los valores del dataset.
25	¿Cuál es la distribución de eventos según `LastVerdict`?	SELECT hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS hora_evento, COUNT(*) AS total_eventos FROM siem_event_logs GROUP BY hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY hora_evento;	Separa las técnicas MITRE cuando vienen juntas en una misma celda, por ejemplo `T1021;T1047;T1105`. Luego cuenta cada técnica por separado.

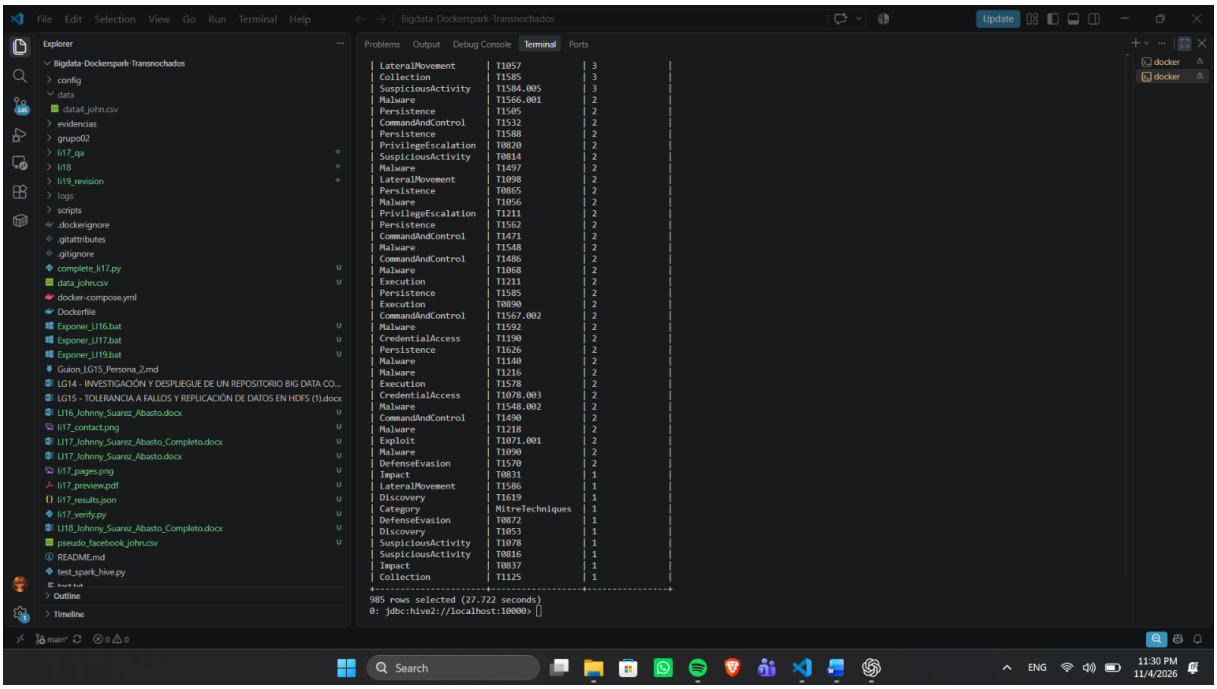
El formato de respuesta esperado debe incluir la imagen de evidencia del SQL ejecutado, asi como la respuesta en sus palabras, similar a:

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
1	¿Qué tipos de entidades aparecen con mayor frecuencia en los eventos?	SELECT EntityType, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY EntityType ORDER BY total_eventos DESC;	Permite identificar qué entidades aparecen con más frecuencia: usuarios, dispositivos, archivos, direcciones IP, aplicaciones u otros activos.



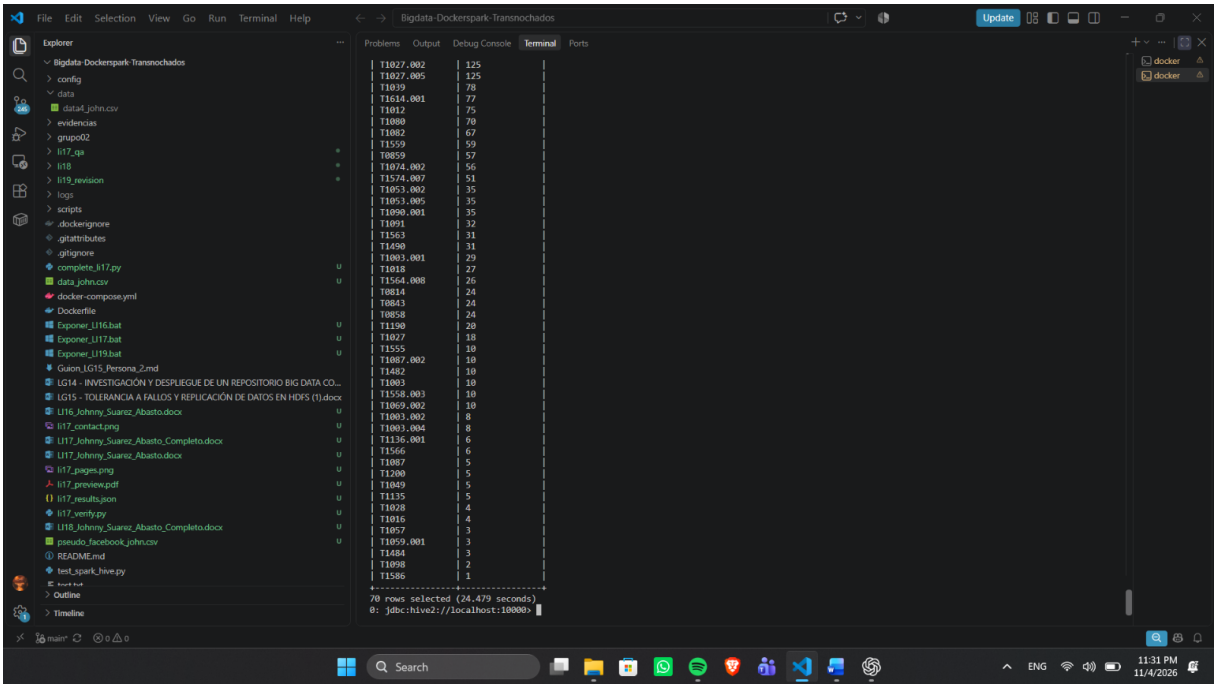
Respuesta a la pregunta (en sus palabras): Encontré más registros de tipo Ip, con 929.684, seguidos por User, con 831.162. Son las entidades que más se repiten en mi resultado.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
2	¿Qué técnicas MITRE aparecen dentro de cada categoría de amenaza?	SELECT Category, trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM db4_john.data4_john LATERAL VIEW explode(split(MitreTechniques, ';')) mitre_table AS tecnica WHERE MitreTechniques IS NOT NULL AND MitreTechniques <> '' AND trim(tecnica) <> '' GROUP BY Category, trim(tecnica) ORDER BY total_eventos DESC;	Relaciona cada categoría de amenaza con las técnicas MITRE detectadas. Sirve para analizar qué técnicas predominan en cada tipo de incidente.



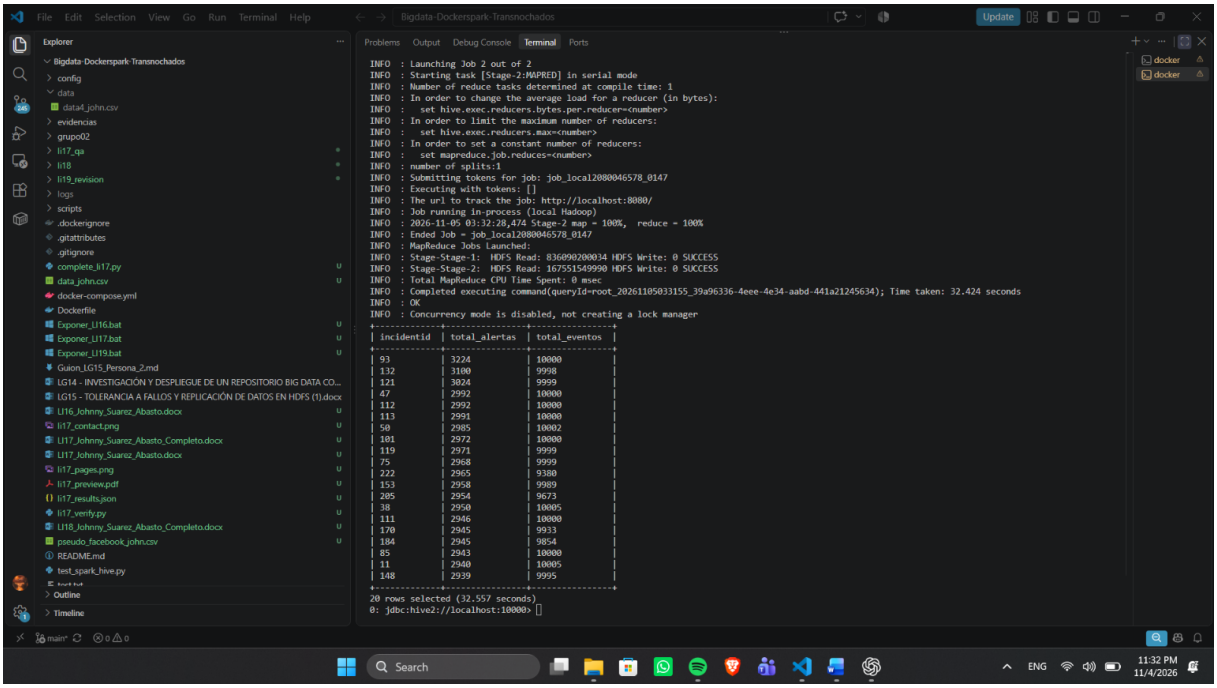
Respuesta a la pregunta (en sus palabras): Obtuve 985 combinaciones de categoría y técnica MITRE. Vi que una categoría puede estar vinculada con varias técnicas, por eso la consulta devuelve tantas filas.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
3	¿Qué técnica MITRE aparece más en eventos de movimiento lateral?	SELECT trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM db4_john.data4_john LATERAL VIEW explode(split(MitreTechniques, ';')) mitre_table AS tecnica WHERE Category = 'LateralMovement' AND MitreTechniques IS NOT NULL AND MitreTechniques <> '' AND trim(tecnica) <> '' GROUP BY trim(tecnica) ORDER BY total_eventos DESC;	Identifica las técnicas MITRE más frecuentes dentro de la categoría `LateralMovement`. Es útil para analizar tácticas relacionadas con desplazamiento lateral dentro de una red.



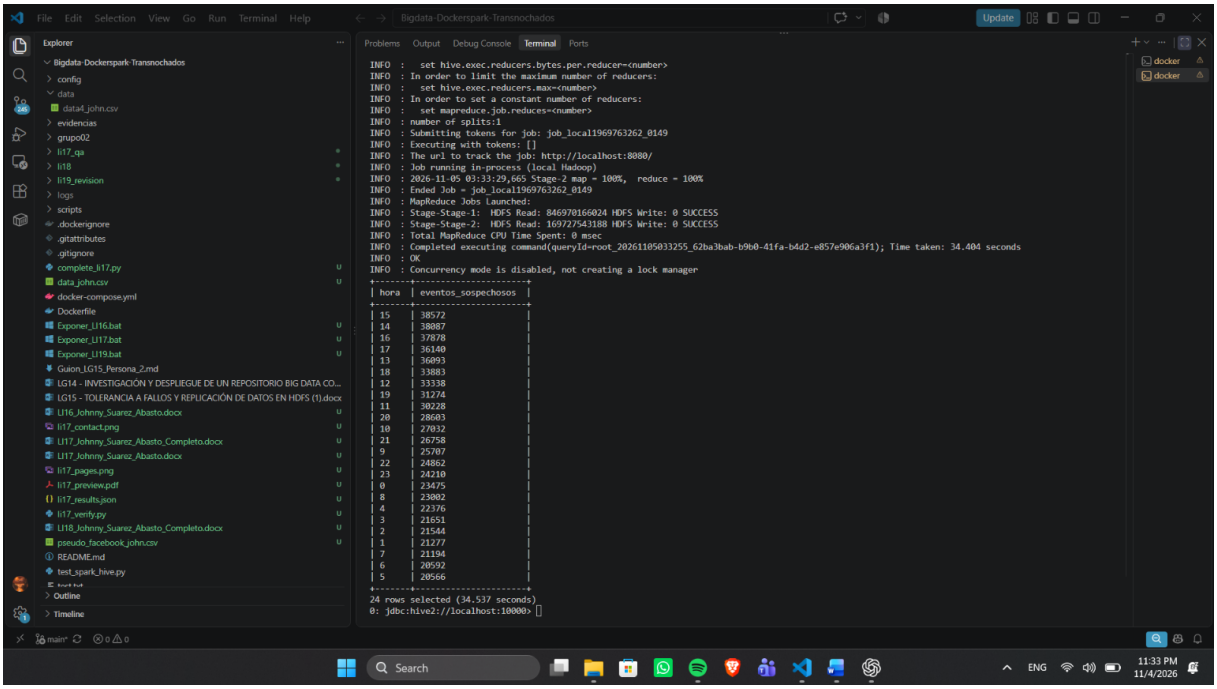
Respuesta a la pregunta (en sus palabras): Encontré 70 técnicas asociadas a LateralMovement. Al separarlas pude contar cada técnica por su cuenta, aunque vinieran juntas en una celda.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
4	¿Qué incidentes concentran más alertas?	SELECT IncidentId, COUNT(DISTINCT AlertId) AS total_alertas, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY IncidentId ORDER BY total_alertas DESC LIMIT 20;	Muestra los incidentes con mayor cantidad de alertas asociadas. Permite identificar incidentes complejos o con gran volumen de evidencias.



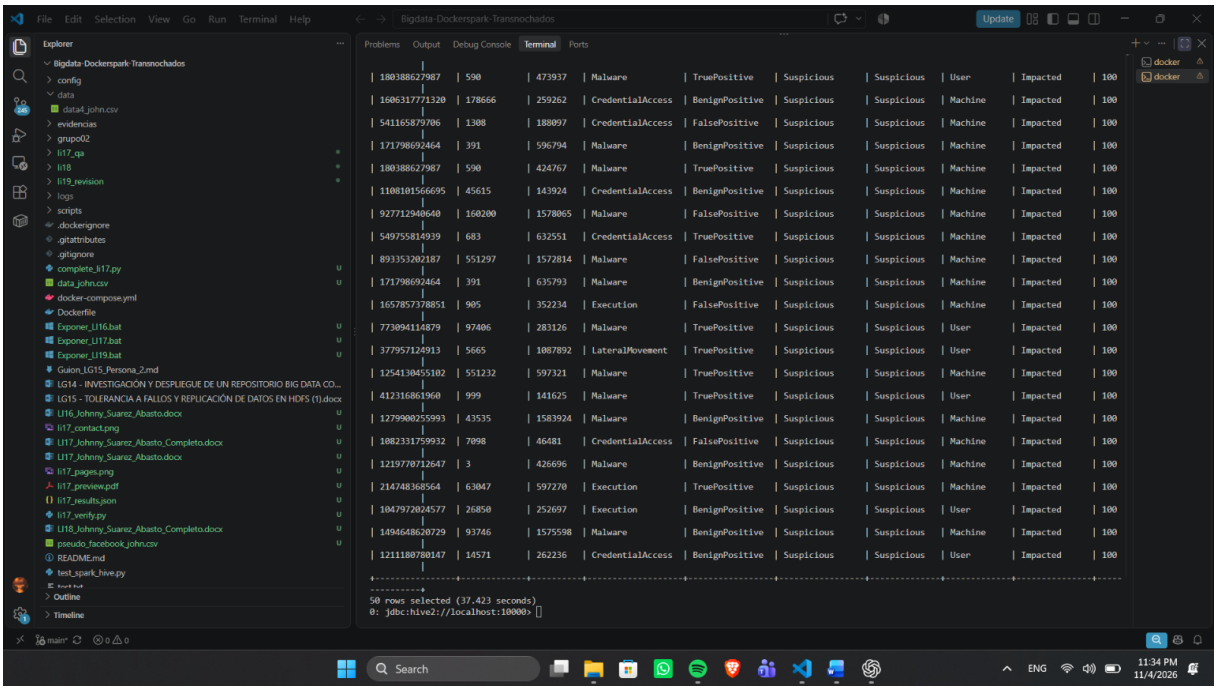
Respuesta a la pregunta (en sus palabras): El incidente 93 quedó primero en mi resultado: reúne 3.224 alertas distintas y 10.000 registros de eventos.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
5	¿Qué horas tienen mayor concentración de eventos sospechosos?	SELECT hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS hora_evento, COUNT(*) AS total_eventos_sospechosos FROM db4_john.data4_john WHERE SuspicionLevel = 'Suspicious' OR LastVerdict = 'Suspicious' GROUP BY hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY total_eventos_sospechosos DESC;	Muestra las horas del día con mayor cantidad de eventos sospechosos. Permite identificar franjas horarias críticas para monitoreo SOC.



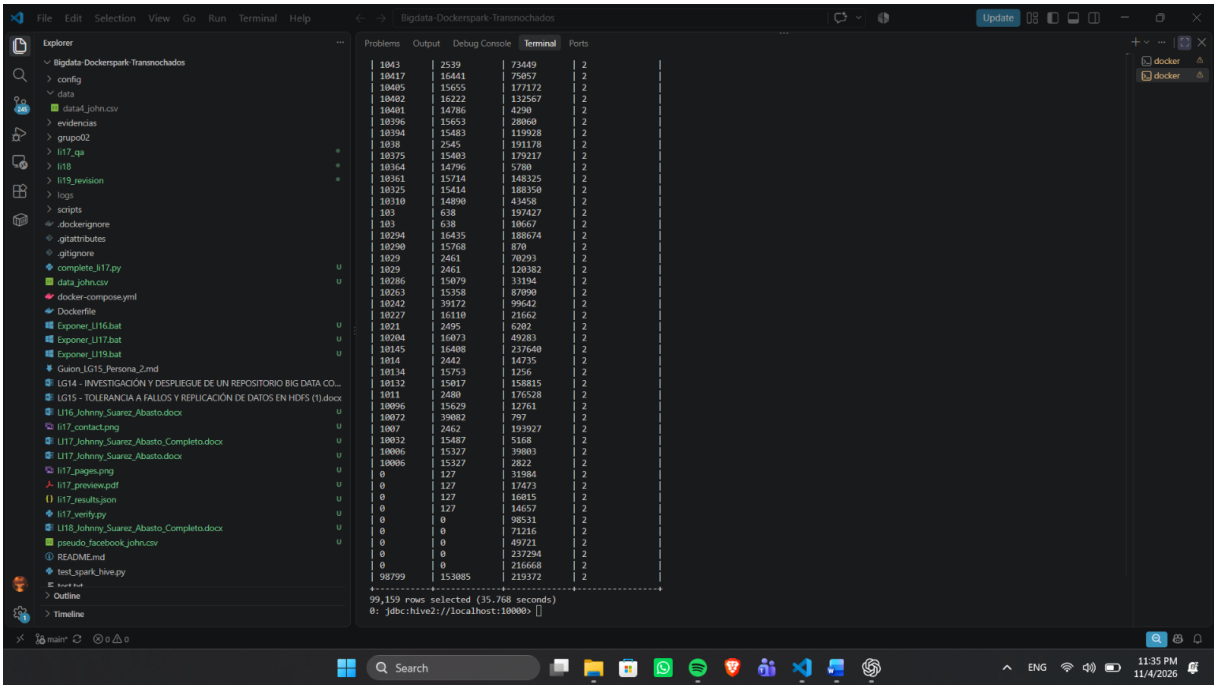
Respuesta a la pregunta (en sus palabras): Vi que las 15:00 tienen la mayor cantidad de registros sospechosos, con 38.572. Tomé la hora tal como aparece en el archivo, sin convertirla a la hora local.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
6	¿Qué eventos pueden considerarse de mayor riesgo usando una regla simple basada en categoría, sospecha y veredicto?	SELECT Id, IncidentId, AlertId, Category, IncidentGrade, SuspicionLevel, LastVerdict, EntityType, EvidenceRole, (CASE WHEN Category IN ('LateralMovement', 'CredentialAccess', 'Malware', 'Execution') THEN 40 ELSE 10 END + CASE WHEN SuspicionLevel = 'Suspicious' THEN 30 ELSE 0 END + CASE WHEN LastVerdict = 'Suspicious' THEN 20 ELSE 0 END + CASE WHEN EvidenceRole = 'Impacted' THEN 10 ELSE 0 END) AS score_riesgo FROM db4_john.data4_john ORDER BY score_riesgo DESC LIMIT 50;	Calcula un puntaje simple de riesgo para priorizar eventos. No reemplaza un SIEM real, pero sirve para practicar reglas de clasificación y priorización SOC.



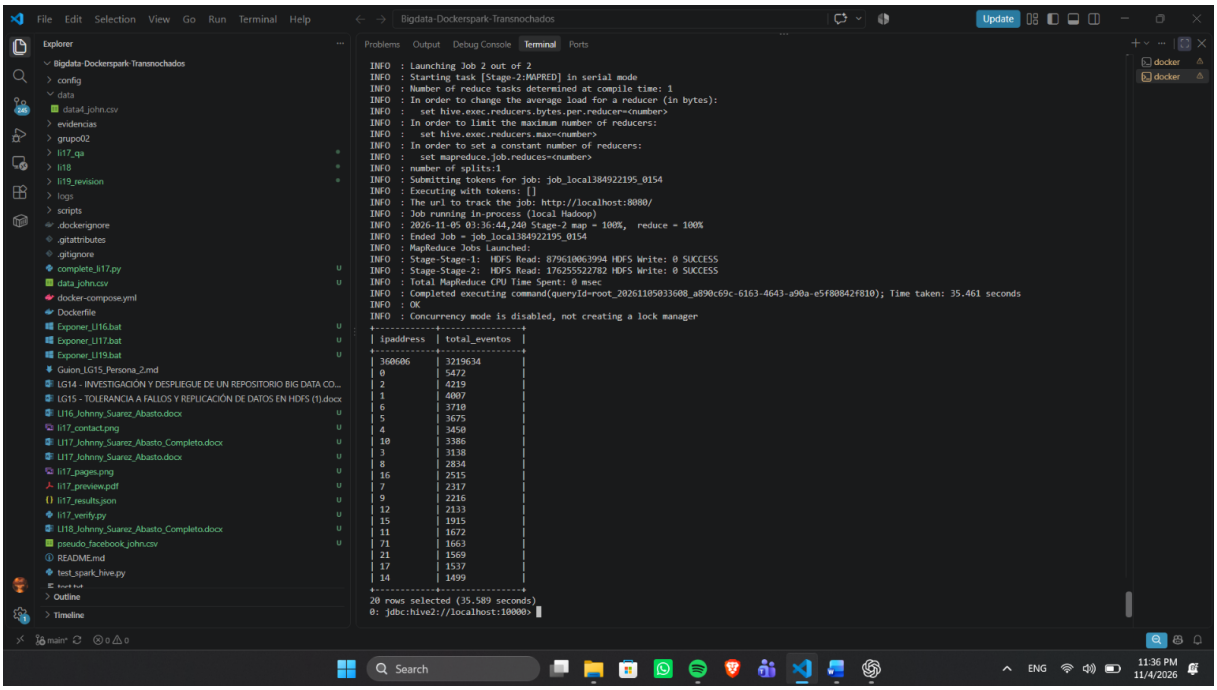
Respuesta a la pregunta (en sus palabras): En los 50 registros mostrados obtuve un puntaje de 100. Ese valor sale de la regla de la consulta; por sí solo no demuestra que todos sean ataques confirmados.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
7	¿Qué dispositivos aparecen en incidentes con más de una alerta?	SELECT DeviceId, DeviceName, IncidentId, COUNT(DISTINCT AlertId) AS total_alertas FROM db4_john.data4_john WHERE DeviceId IS NOT NULL GROUP BY DeviceId, DeviceName, IncidentId HAVING COUNT(DISTINCT AlertId) > 1 ORDER BY total_alertas DESC;	Muestra dispositivos asociados a incidentes que tienen más de una alerta. Puede ayudar a identificar equipos involucrados en incidentes más complejos o persistentes.



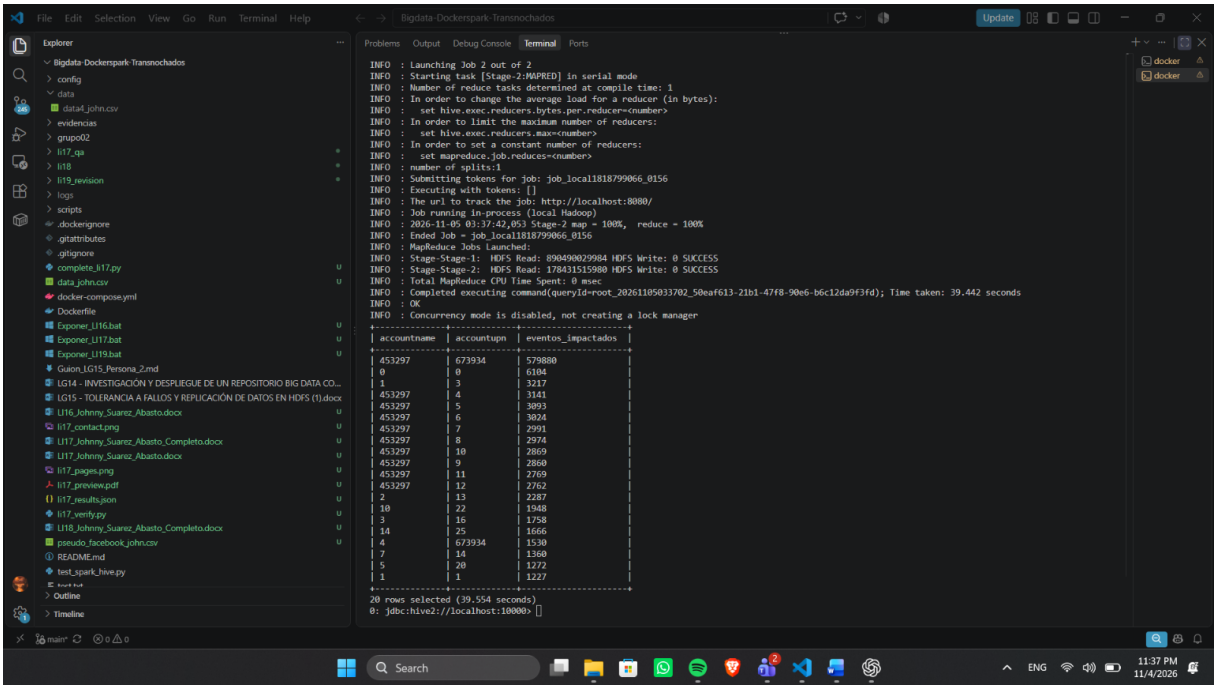
Respuesta a la pregunta (en sus palabras): Obtuve 99.159 combinaciones de dispositivo e incidente con más de una alerta distinta. No las interpreté como 99.159 dispositivos únicos, porque un equipo puede aparecer en varios incidentes.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
8	¿Qué direcciones IP aparecen más veces en los eventos?	SELECT IpAddress, COUNT(*) AS total_eventos FROM db4_john.data4_john WHERE IpAddress IS NOT NULL AND IpAddress <> '' GROUP BY IpAddress ORDER BY total_eventos DESC LIMIT 20;	Muestra las direcciones IP con mayor cantidad de eventos. Permite identificar IP internas o externas que aparecen repetidamente en los registros.



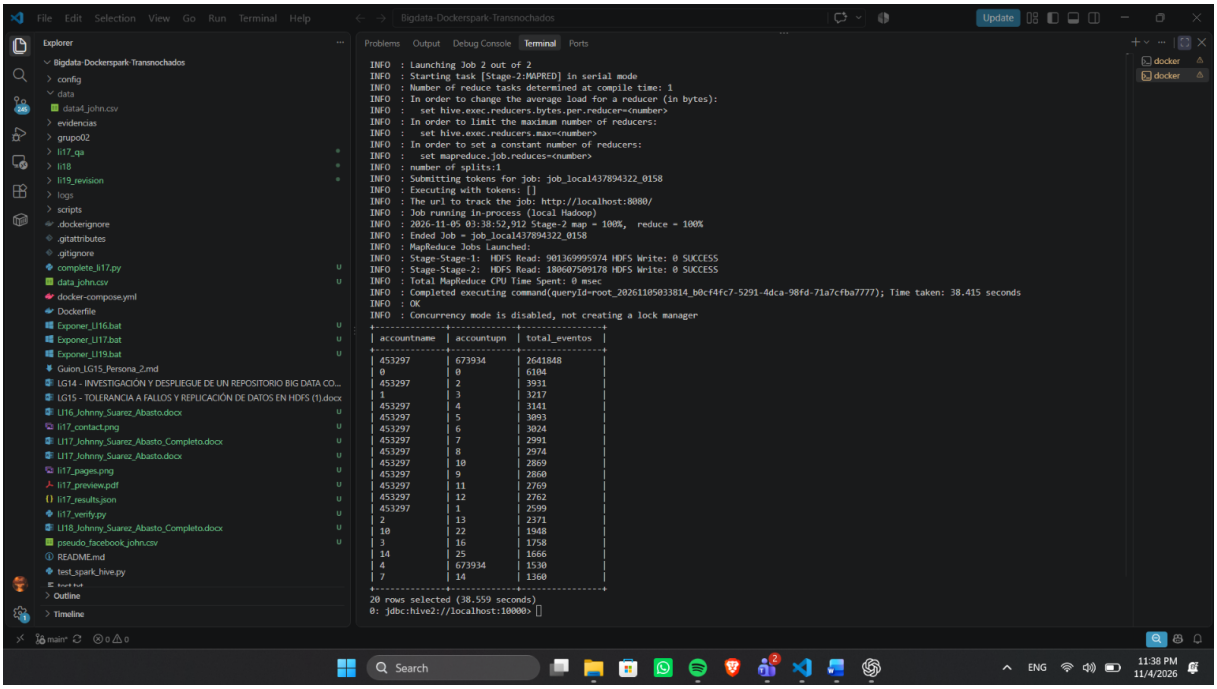
Respuesta a la pregunta (en sus palabras): El identificador 360606 aparece primero, con 3.219.634 registros. En este archivo el campo de IP contiene códigos, así que no puedo identificar una dirección real a partir de ese número.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
9	¿Qué cuentas están asociadas a eventos con evidencia impactada?	SELECT AccountName, AccountUpn, COUNT(*) AS total_eventos_impactados FROM db4_john.data4_john WHERE EvidenceRole = 'Impacted' AND (AccountName IS NOT NULL OR AccountUpn IS NOT NULL) GROUP BY AccountName, AccountUpn ORDER BY total_eventos_impactados DESC LIMIT 20;	Identifica cuentas vinculadas directamente a evidencias impactadas. Es útil para priorizar usuarios posiblemente afectados o comprometidos.



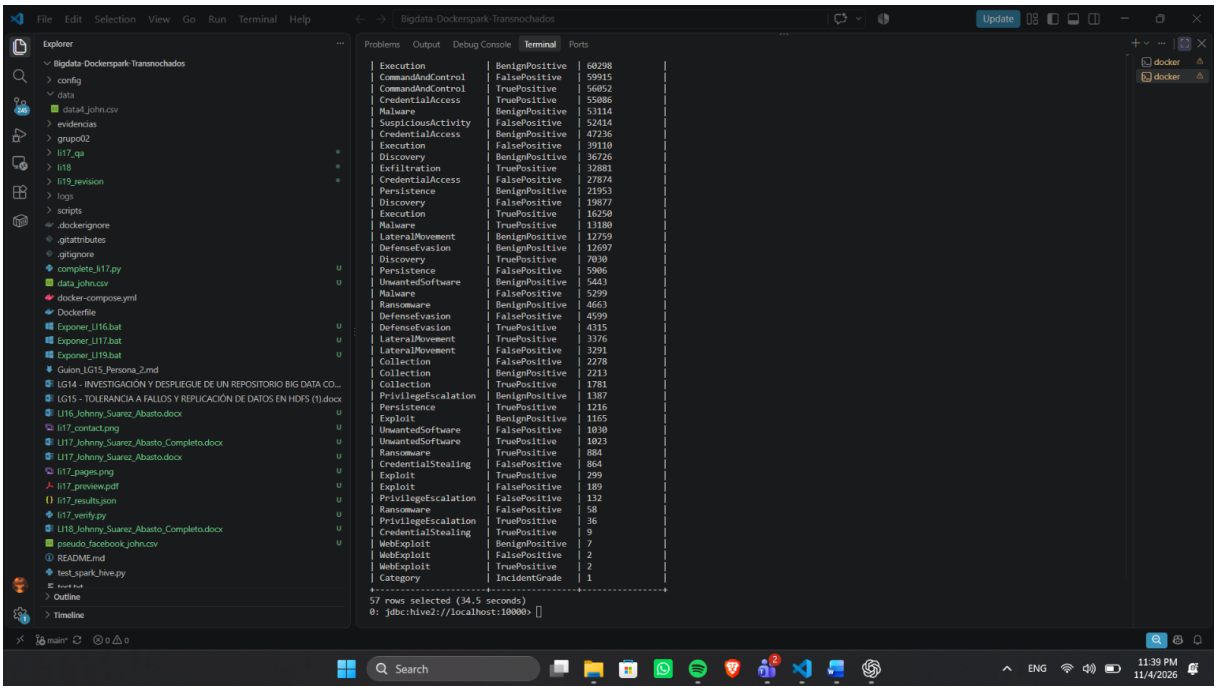
Respuesta a la pregunta (en sus palabras): La combinación de cuenta 453297 y UPN 673934 reunió 579.880 registros con evidencia impactada. Esto me permite ubicar el grupo con más registros afectados, aunque los nombres están codificados.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
10	¿Qué cuentas de usuario aparecen con mayor frecuencia en los eventos?	SELECT AccountName, AccountUpn, COUNT(*) AS total_eventos FROM db4_john.data4_john WHERE (AccountName IS NOT NULL AND AccountName <> '') OR (AccountUpn IS NOT NULL AND AccountUpn <> '') GROUP BY AccountName, AccountUpn ORDER BY total_eventos DESC LIMIT 20;	Identifica las cuentas de usuario más asociadas a eventos de seguridad. Es útil para detectar cuentas comprometidas o usuarios con actividad sospechosa.



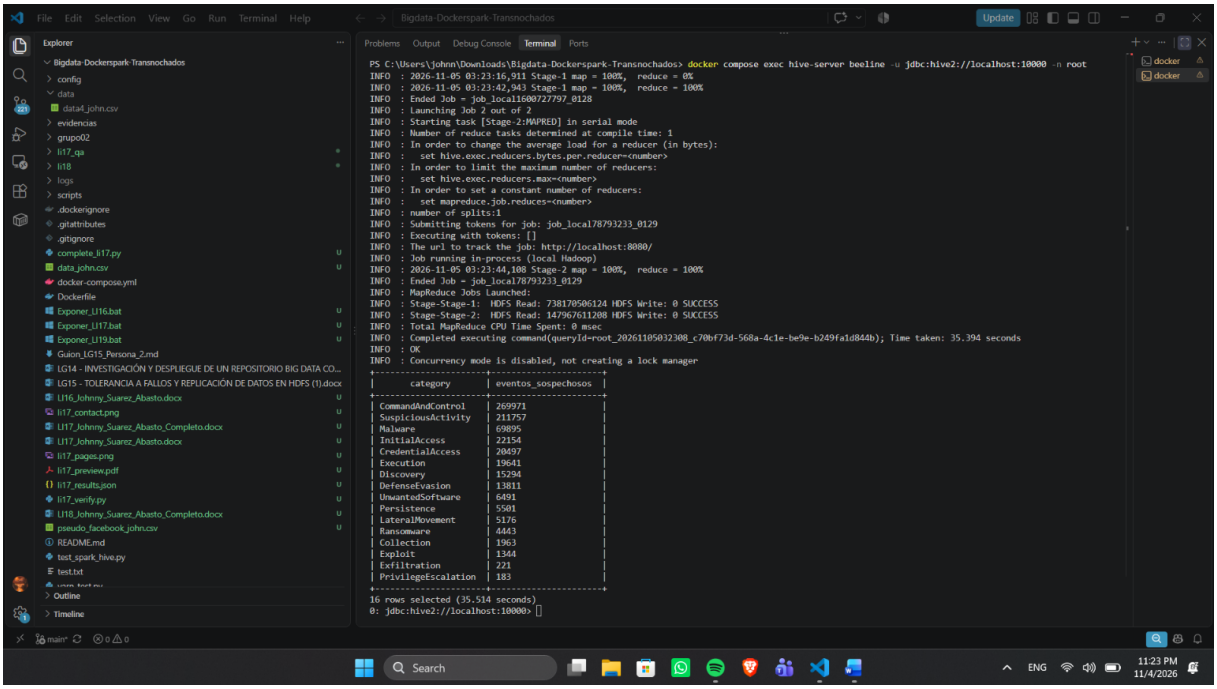
Respuesta a la pregunta (en sus palabras): La combinación 453297 y 673934 quedó primera, con 2.641.848 registros. La frecuencia me sirve para priorizar su revisión, pero no basta para afirmar que sea una cuenta comprometida.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
11	¿Qué categorías tienen más eventos según el grado del incidente?	SELECT Category, IncidentGrade, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY Category, IncidentGrade ORDER BY total_eventos DESC;	Relaciona la categoría del evento con el grado del incidente. Permite saber qué categorías se asocian más con incidentes benignos, sospechosos o confirmados.



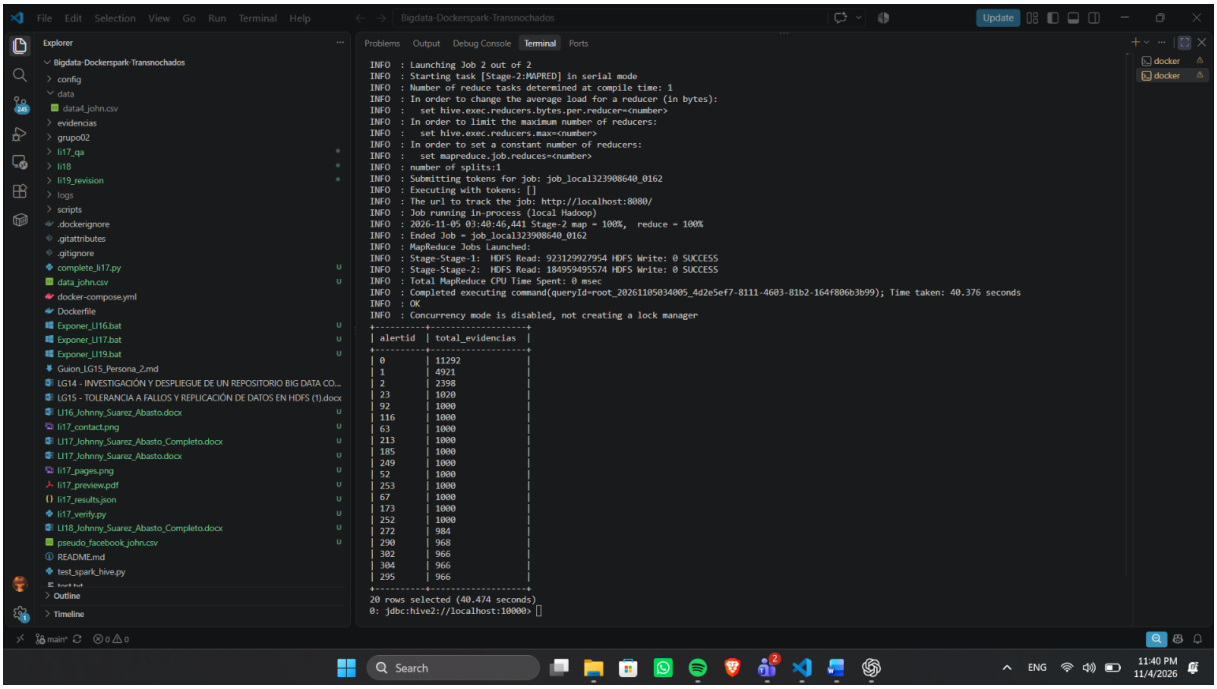
Respuesta a la pregunta (en sus palabras): Obtuve 57 combinaciones de categoría y grado del incidente. También apareció la combinación Category e IncidentGrade una vez, lo que indica que hay una fila de encabezados dentro de los datos.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
12	¿Qué categoría tiene mayor cantidad de eventos sospechosos?	SELECT Category, COUNT(*) AS total_sospechosos FROM db4_john.data4_john WHERE SuspicionLevel = 'Suspicious' OR LastVerdict = 'Suspicious' GROUP BY Category ORDER BY total_sospechosos DESC;	Muestra qué categorías concentran más eventos sospechosos. Sirve para identificar los tipos de amenazas que requieren mayor atención del analista.



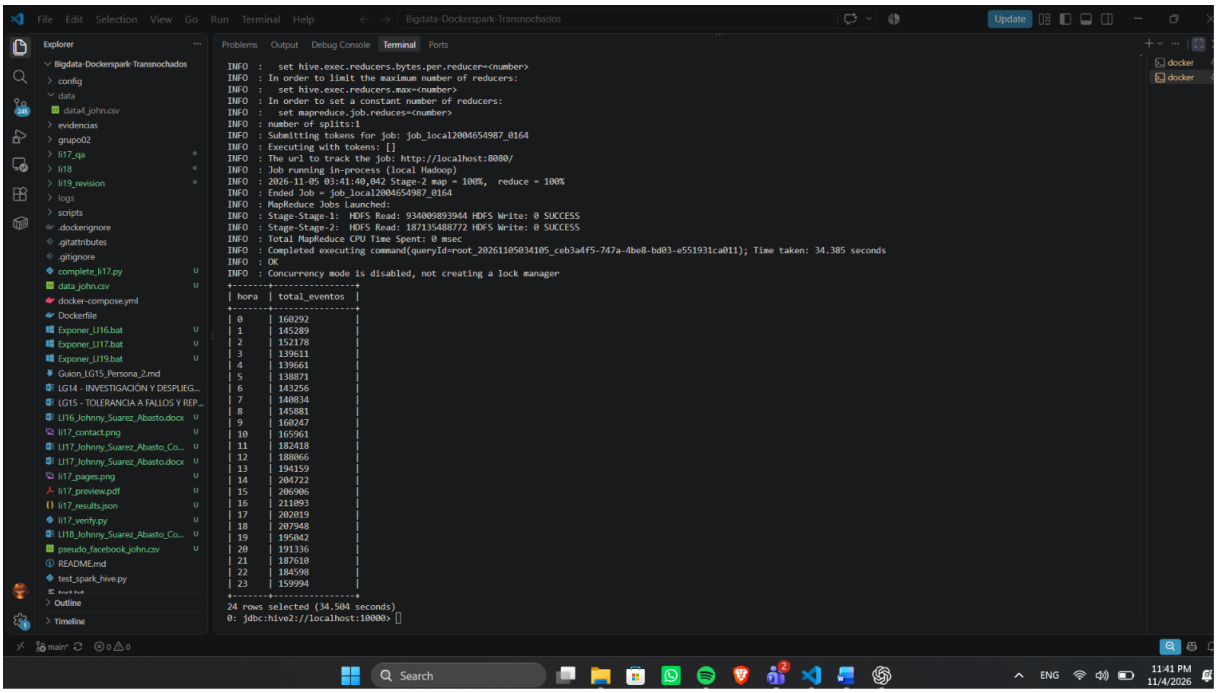
Respuesta a la pregunta (en sus palabras): CommandAndControl quedó primero, con 269.971 registros sospechosos. Para este conteo incluí los que tenían Suspicious en el nivel de sospecha o en el veredicto.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
13	¿Qué alertas tienen más evidencias asociadas?	SELECT AlertId, COUNT(*) AS total_evidencias FROM db4_john.data4_john GROUP BY AlertId ORDER BY total_evidencias DESC LIMIT 20;	Muestra las alertas que tienen mayor cantidad de evidencias registradas. Sirve para identificar alertas con múltiples entidades, archivos, usuarios o dispositivos involucrados.



Respuesta a la pregunta (en sus palabras): La alerta 0 reunió 11.292 registros de evidencia y quedó primera. Conté las filas asociadas a cada alerta, no alertas diferentes.

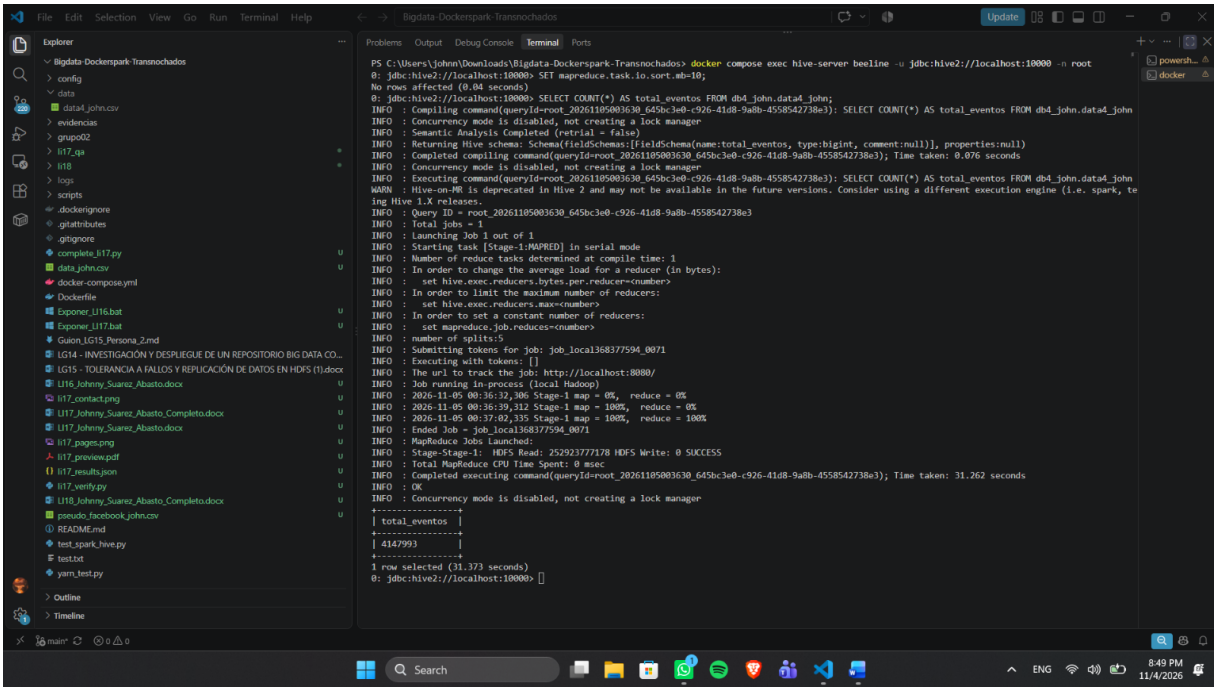
Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
14	¿En qué horas del día se generan más eventos SIEM?	SELECT hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS hora_evento, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY hour(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY hora_evento;	Muestra la cantidad de eventos por hora, de 0 a 23. Sirve para identificar las franjas horarias con mayor actividad de seguridad.



```
INFO  :   set hive.exec.reducers.bytes.per.reducer=<number>
INFO  : In order to limit the maximum number of reducers:
INFO  :   set hive.exec.reducers.max=<number>
INFO  : In order to set a constant number of reducers:
INFO  :   set mapreduce.job.reduces=<number>
INFO  : number of splits:1
INFO  : Submitting tokens for job: job_local2004654987_0164
INFO  : Executing with tokens: []
INFO  : The url to track the job: http://localhost:8080/
INFO  : Job running in-process (local Hadoop)
INFO  : 2026-11-05 03:41:40,042 Stage-2 map = 100%,  reduce = 100%
INFO  : Ended Job = job_local2004654987_0164
INFO  : MapReduce Jobs Launched:
INFO  : Stage-Stage-1:  HDFS Read: 934009893944 HDFS Write: 0 SUCCESS
INFO  : Stage-Stage-2:  HDFS Read: 187135488772 HDFS Write: 0 SUCCESS
INFO  : Total MapReduce CPU Time Spent: 0 msec
INFO  : Completed executing command(queryId=root_20261105034105_ceb3a4f5-747a-4be8-bd03-e551931ca011); Time taken: 34.385 seconds
INFO  : OK
INFO  : Concurrency mode is disabled, not creating a lock manager
+-------+----------------+
| hora  | total_eventos  |
+-------+----------------+
| 0     | 160292         |
| 1     | 145289         |
| 2     | 152178         |
| 3     | 139611         |
| 4     | 139661         |
| 5     | 138871         |
| 6     | 143256         |
| 7     | 140834         |
| 8     | 145881         |
| 9     | 160247         |
| 10    | 165961         |
| 11    | 182418         |
| 12    | 188066         |
| 13    | 194159         |
| 14    | 204722         |
| 15    | 206906         |
| 16    | 211093         |
| 17    | 202019         |
| 18    | 207948         |
| 19    | 195042         |
| 20    | 191336         |
| 21    | 187610         |
| 22    | 184598         |
| 23    | 159994         |
+-------+----------------+
24 rows selected (34.504 seconds)
0: jdbc:hive2://localhost:10000>
```

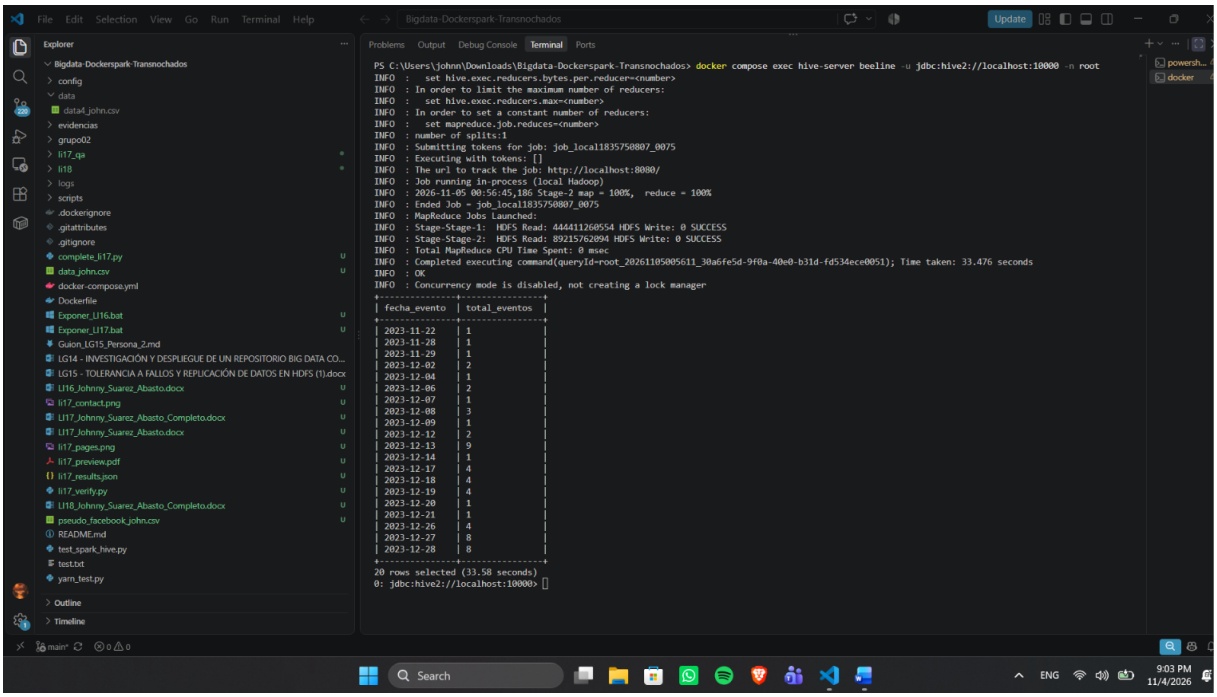
Respuesta a la pregunta (en sus palabras): La hora 16 tuvo el mayor conteo, con 211.093 registros. Comparé las 24 horas usando la hora registrada en el archivo.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
15	¿Cuántos eventos SIEM existen en el dataset?	SELECT COUNT(*) AS total_eventos FROM db4_john.data4_john;	Se obtiene la cantidad total de registros cargados en la tabla. Sirve para validar si el CSV fue cargado correctamente en Hive.



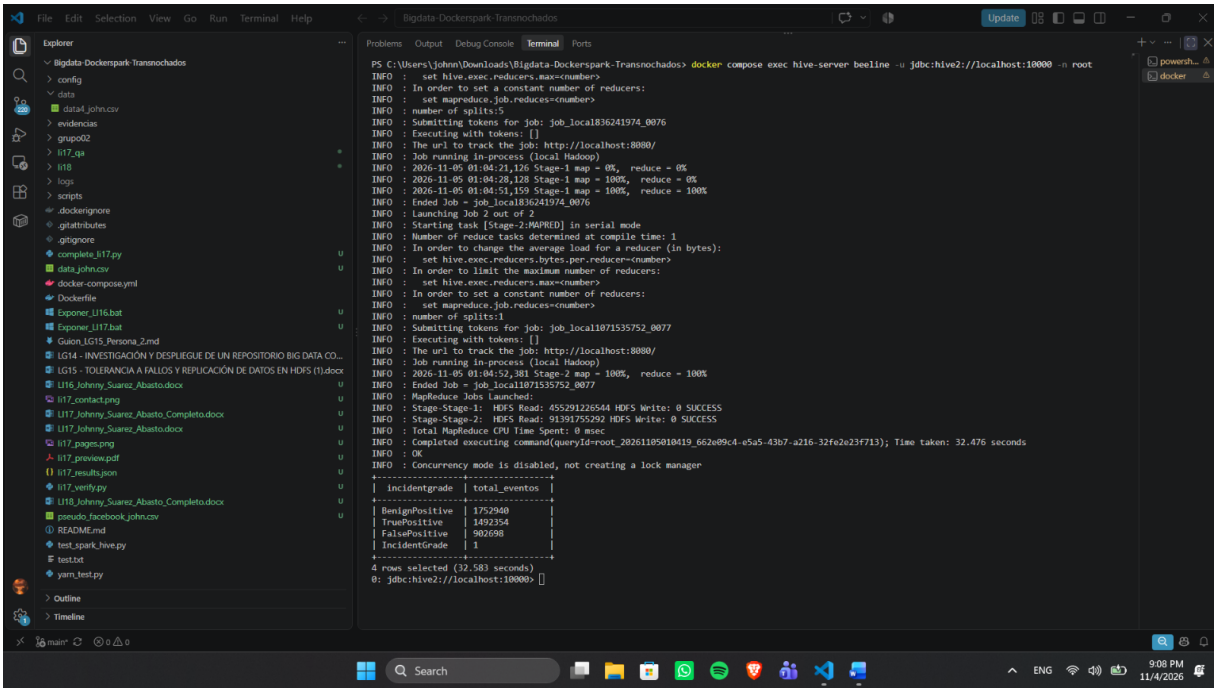
Respuesta a la pregunta (en sus palabras): Obtuve 4.147.993 registros. Vi que el total incluye una fila con nombres de columnas; por eso hay un registro más que los 4.147.992 del ejemplo.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
16	¿Cuántos eventos se registraron por día?	SELECT to_date(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) AS fecha_evento, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY to_date(from_unixtime(unix_timestamp(`Timestamp`, "yyyy-MM-dd'T'HH:mm:ss.SSS'Z'"))) ORDER BY fecha_evento;	Agrupa los eventos por fecha. Permite observar días con mayor actividad o picos anómalos de eventos.



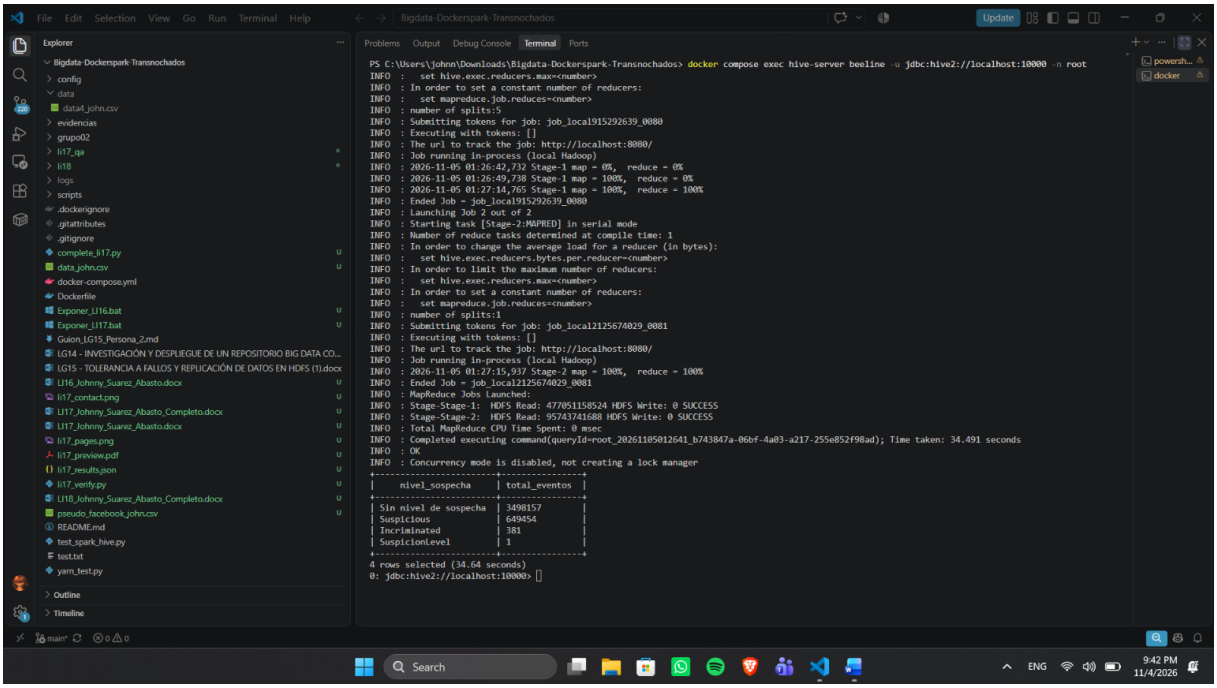
Respuesta a la pregunta (en sus palabras): Agrupé los registros por día y pude ver cómo cambia la cantidad entre fechas. Mi captura muestra solo las primeras 20 fechas del resultado.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
17	¿Cuántos eventos existen por cada tipo de `IncidentGrade`?	SELECT IncidentGrade, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY IncidentGrade ORDER BY total_eventos DESC;	Se obtiene la distribución de eventos según su clasificación, por ejemplo benignos, sospechosos, positivos verdaderos o falsos positivos, dependiendo de los valores del dataset.



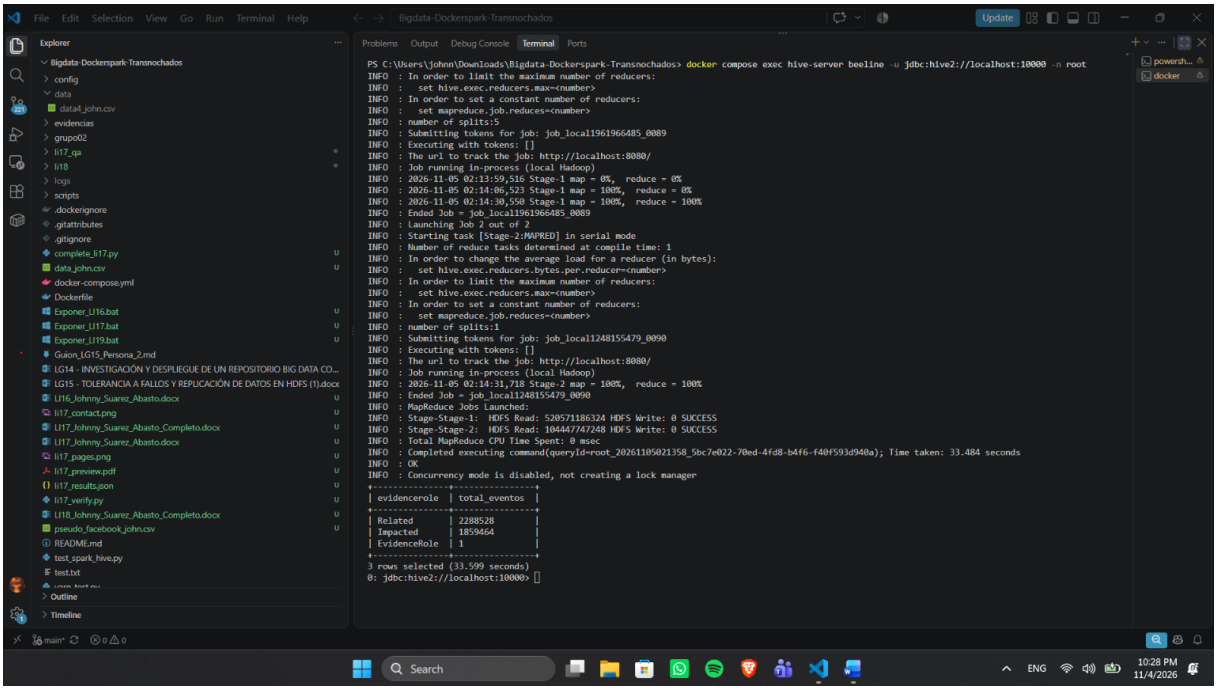
Respuesta a la pregunta (en sus palabras): Obtuve 1.752.940 BenignPositive, 1.492.354 TruePositive y 902.698 FalsePositive. También apareció IncidentGrade una vez, correspondiente a una fila de encabezados.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
18	¿Cuántos eventos existen por cada nivel de sospecha?	SELECT CASE WHEN SuspicionLevel IS NULL OR SuspicionLevel = '' THEN 'Sin nivel de sospecha' ELSE SuspicionLevel END AS nivel_sospecha, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY CASE WHEN SuspicionLevel IS NULL OR SuspicionLevel = '' THEN 'Sin nivel de sospecha' ELSE SuspicionLevel END ORDER BY total_eventos DESC;	Agrupa los eventos según el nivel de sospecha. Ayuda a identificar cuántos eventos fueron clasificados como sospechosos, desconocidos o sin clasificación.



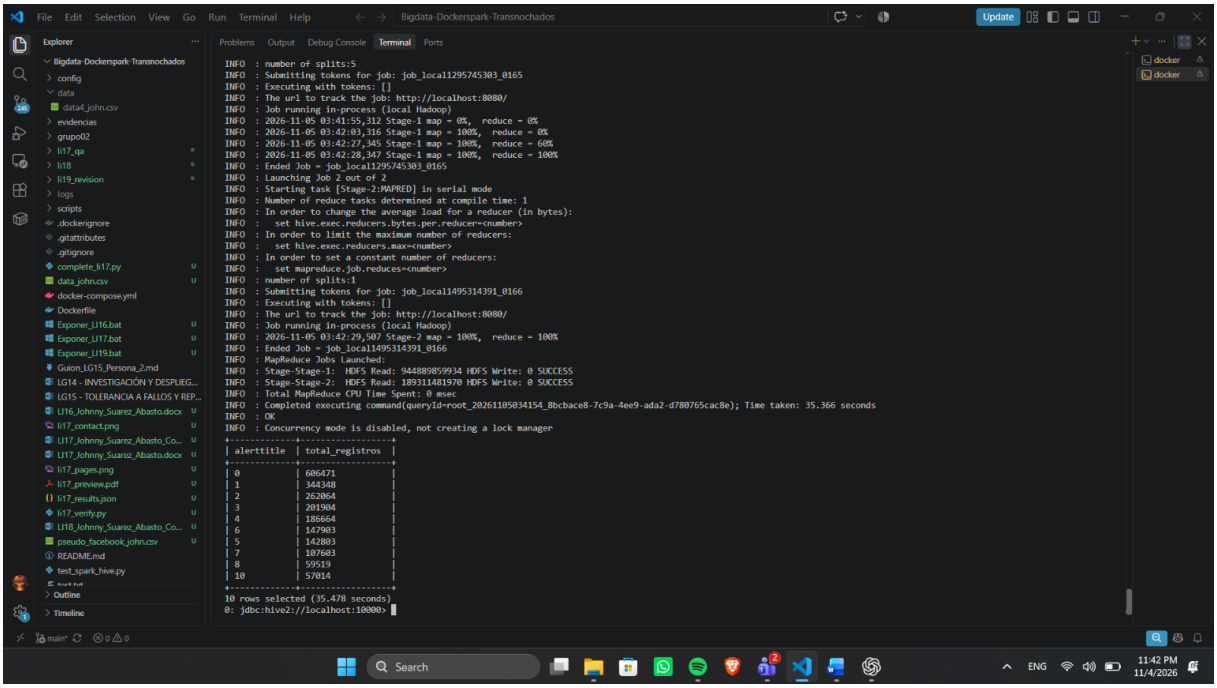
Respuesta a la pregunta (en sus palabras): Encontré 3.498.157 registros sin nivel de sospecha, 649.454 Suspicious y 381 Incriminated. Además apareció SuspicionLevel una vez como dato de encabezado.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
19	¿Cuántos eventos corresponden a evidencias impactadas y cuántos a evidencias relacionadas?	SELECT EvidenceRole, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY EvidenceRole ORDER BY total_eventos DESC;	Muestra la cantidad de eventos según el rol de la evidencia. Ayuda a diferenciar entidades directamente afectadas de entidades solo relacionadas con el incidente.



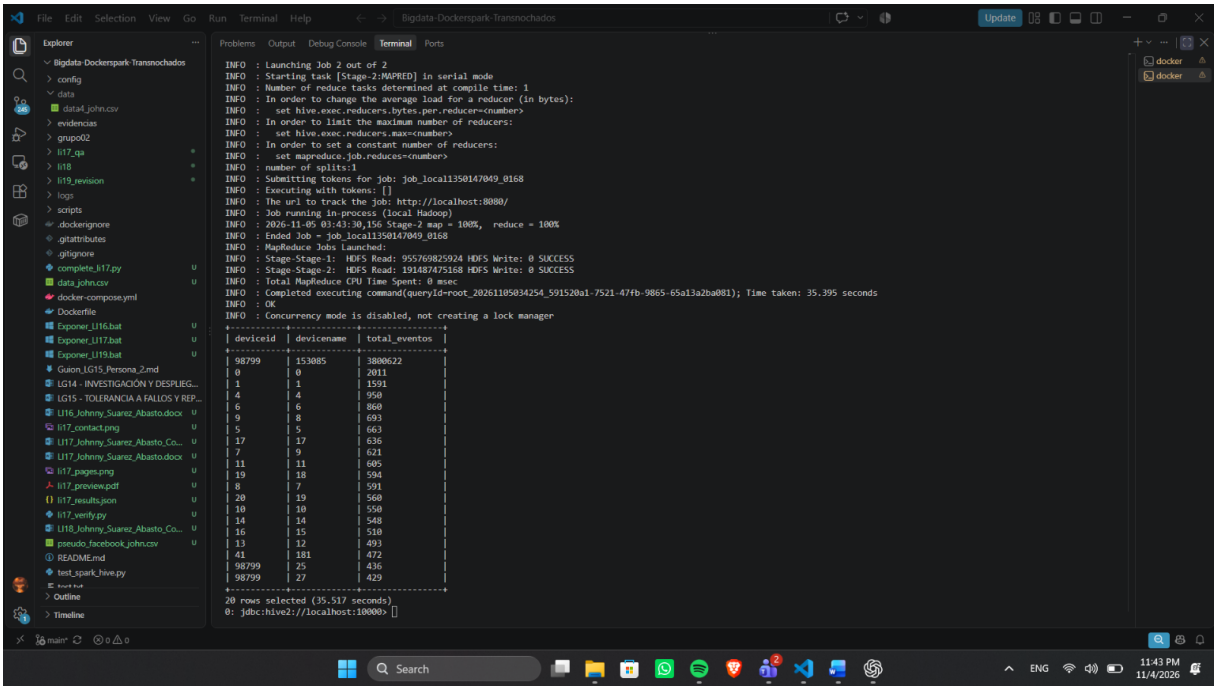
Respuesta a la pregunta (en sus palabras): Conté 2.288.528 registros Related y 1.859.464 Impacted. Predominan las evidencias relacionadas; también encontré una fila con el texto EvidenceRole.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
20	¿Cuáles son los títulos de alerta más repetidos en el dataset?	SELECT AlertTitle, COUNT(*) AS total_alertas FROM db4_john.data4_john GROUP BY AlertTitle ORDER BY total_alertas DESC LIMIT 10;	Muestra los títulos de alerta más frecuentes. Ayuda a detectar alertas repetitivas o patrones que podrían requerir revisión o ajuste.



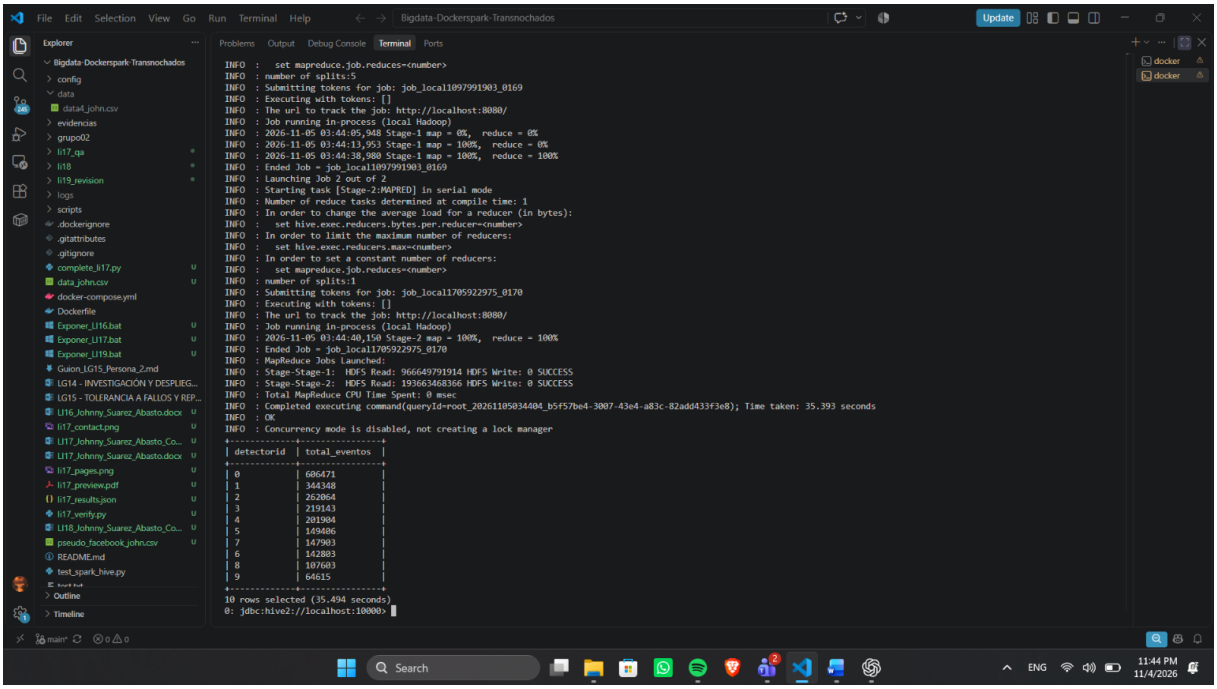
Respuesta a la pregunta (en sus palabras): El título codificado como 0 apareció en 606.471 registros y fue el más repetido. Este resultado cuenta registros por título, no alertas únicas.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
21	¿Cuáles son los dispositivos con mayor cantidad de eventos?	SELECT DeviceId, DeviceName, COUNT(*) AS total_eventos FROM db4_john.data4_john WHERE DeviceId IS NOT NULL GROUP BY DeviceId, DeviceName ORDER BY total_eventos DESC LIMIT 20;	Obtiene un ranking de dispositivos con más eventos. Puede ayudar a detectar equipos comprometidos, expuestos o con actividad anómala.



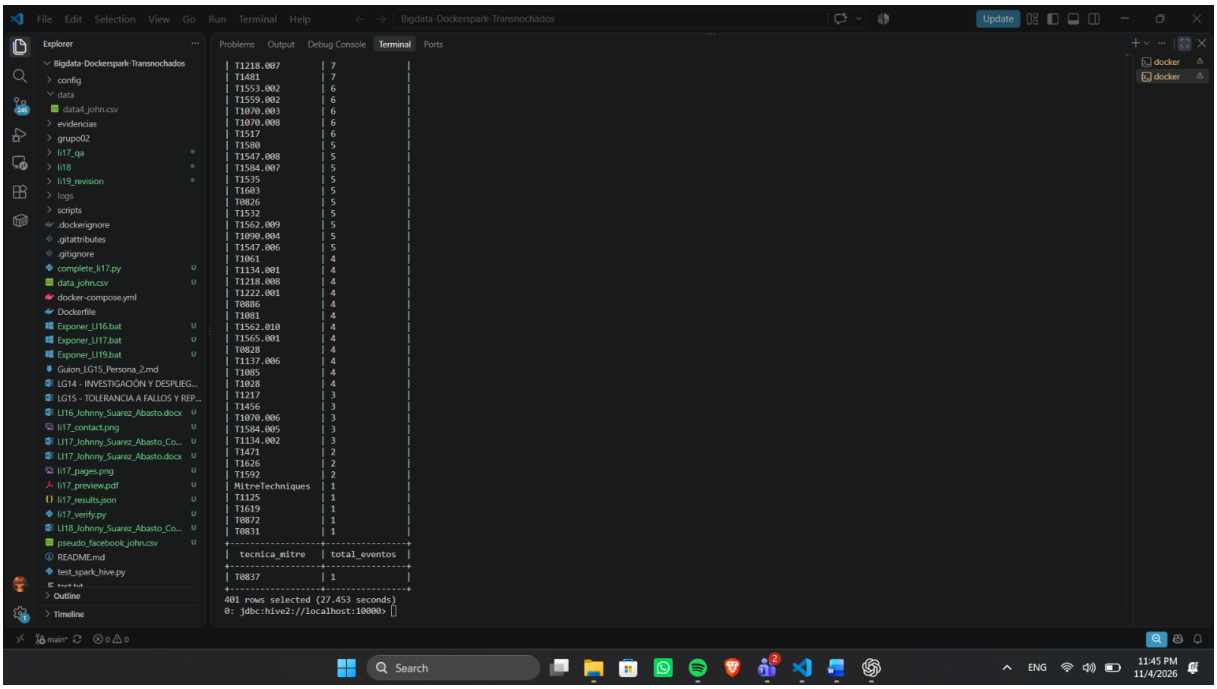
Respuesta a la pregunta (en sus palabras): La combinación de dispositivo 98799 y nombre 153085 quedó primera. Como son identificadores codificados, el resultado no me permite saber qué equipo físico representa.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
22	¿Cuáles son los detectores que generan mayor cantidad de alertas?	SELECT DetectorId, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY DetectorId ORDER BY total_eventos DESC LIMIT 10;	Identifica los 10 detectores con mayor volumen de eventos. Permite reconocer reglas, sensores o mecanismos de detección que generan más alertas.



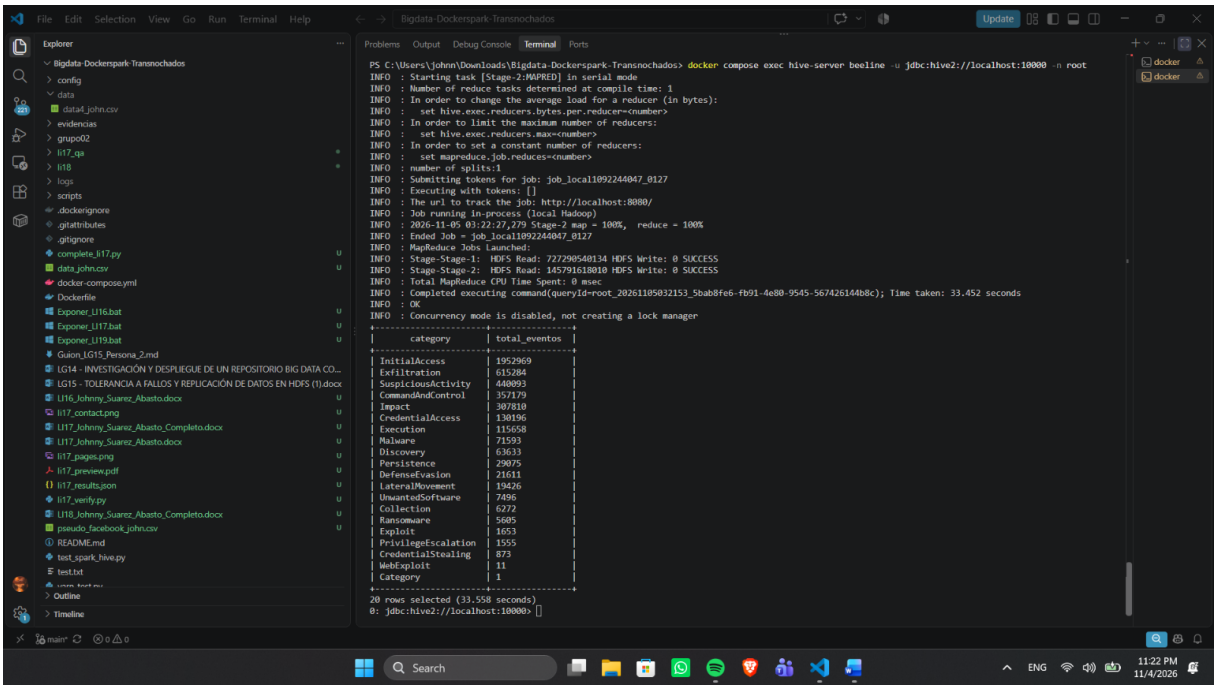
Respuesta a la pregunta (en sus palabras): El detector 0 quedó primero, con 606.471 registros. Usé este conteo para comparar el volumen por detector; no representa necesariamente esa cantidad de alertas distintas.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
23	¿Cuáles son las técnicas MITRE ATT&CK más utilizadas o detectadas?	SELECT trim(tecnica) AS mitre_technique, COUNT(*) AS total_eventos FROM (SELECT explode(split(MitreTechniques, ';')) AS tecnica FROM db4_john.data4_john WHERE MitreTechniques IS NOT NULL AND MitreTechniques <> '') t WHERE trim(tecnica) <> '' GROUP BY trim(tecnica) ORDER BY total_eventos DESC;	Separa las técnicas MITRE cuando vienen juntas en una misma celda, por ejemplo `T1021;T1047;T1105`. Luego cuenta cada técnica por separado.



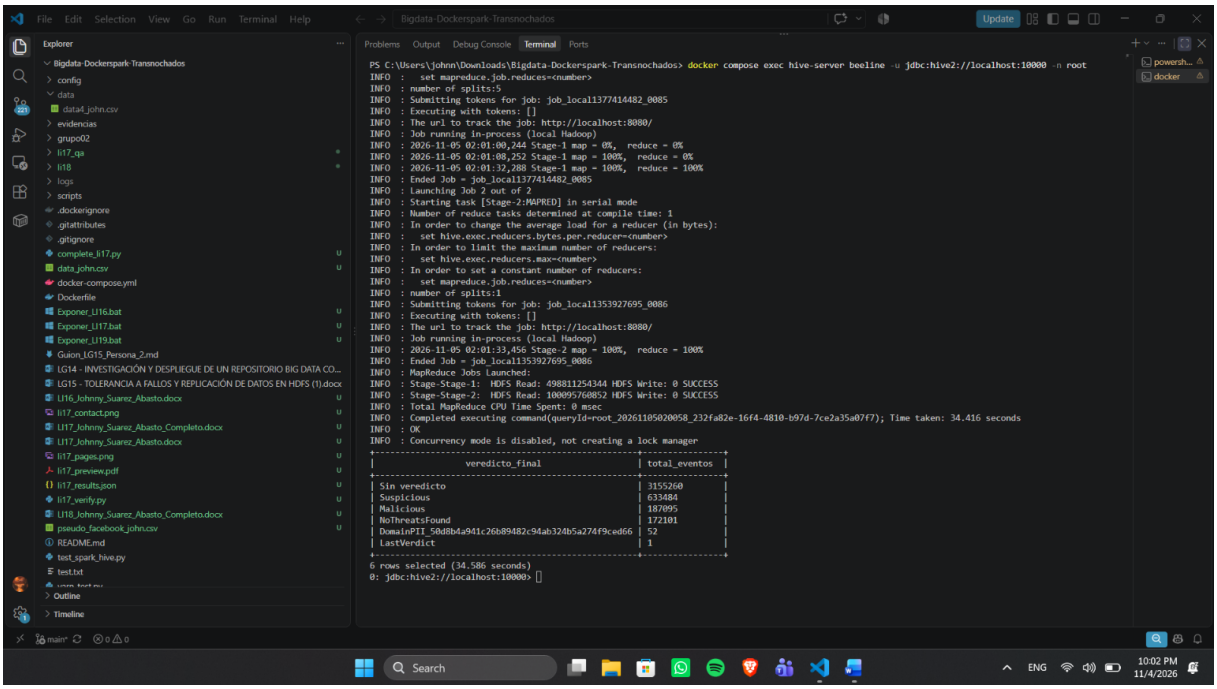
Respuesta a la pregunta (en sus palabras): Obtuve 401 valores al separar y contar las técnicas MITRE. En el resultado también apareció MitreTechniques, así que ese encabezado debe excluirse antes de interpretar el conteo como técnicas válidas.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
24	¿Cuáles son las categorías de eventos más frecuentes?	SELECT Category, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY Category ORDER BY total_eventos DESC;	Muestra un ranking de categorías de eventos, por ejemplo `LateralMovement`, `Malware`, `CredentialAccess`, entre otras. Permite identificar los tipos de amenazas más frecuentes.



Respuesta a la pregunta (en sus palabras): InitialAccess fue la categoría más frecuente, con 1.952.969 registros. En mi resultado concentra más eventos que las demás categorías.

Nro.	Pregunta	SQL solución	Descripción de lo que se obtiene
25	¿Cuál es la distribución de eventos según `LastVerdict`?	SELECT CASE WHEN LastVerdict IS NULL OR LastVerdict = '' THEN 'Sin veredicto' ELSE LastVerdict END AS veredicto_final, COUNT(*) AS total_eventos FROM db4_john.data4_john GROUP BY CASE WHEN LastVerdict IS NULL OR LastVerdict = '' THEN 'Sin veredicto' ELSE LastVerdict END ORDER BY total_eventos DESC;	Muestra cuántos eventos tienen veredicto final, por ejemplo sospechoso, benigno, malicioso o sin veredicto. Sirve para evaluar el resultado del análisis de seguridad.



Respuesta a la pregunta (en sus palabras): Encontré 3.155.260 registros sin veredicto, 633.484 Suspicious, 187.095 Malicious y 172.101 NoThreatsFound. También vi otros valores que necesitan revisión, incluido el encabezado LastVerdict.